MUNI FSS Institut pro psychologický výzkum

pdb 2026

Workshop: Tvorba kontinuálních norem při vývoji psychodiagnostických metod

Hynek Cígler
Institut pro psychologický výzkum, FSS, Masarykova univerzita

Konference **Psychologická diagnostika Brno 2026** | 22. říjen


10
Joštova
218
Brno-město
VYMÝVÁNÍ MOZKŮ
pondělí - pátek: 8 - 16 hod.
(Individuální zákroky po dohodě s rektorem)
FAKULTA SOCIÁLNÍCH
STUDIÍ


MASARYKOVA UNIVERZITA
NAŠE ŠKOLA SE PYŠNÍ
PRŮMĚRNÝM STUDENTSKÝM
IQ: 63,15 %
FAKULTA SOCIÁLNÍCH
STUDIÍ

Harmonogram

Orientační harmonogram:

- Úvod do norem obecně, výběrová chyba a dopad na měření.
- Formalizace norem. Normy jako funkce, horizontální a vertikální normativní funkce.
- Nenormálně rozložené skóry, normalizace distribuce.
- Potřeba a principy horizontálního a vertikálního vyhlazení.
- Běžné postupy pro kontinuální normování.
- Teorie cNORM přístupu.
- Praktická ilustrace: společně.
- Praktická ilustrace: individuálně.

Veškeré materiály ke stažení: https://github.com/hynekcigler/cnorm_workshop

Normy obecně

V psychologii nemáme až na výjimky dostatečně identifikované a interpretovatelné jednotky.

- Chybí koordinační funkce a kalibrace měřítka.
- Dokonce i W-skóre je závislé na průměrné diskriminační účinnosti položek a měřítko se liší napříč testy.
  - S jednou výjimkou... viz moje přednáška o M-skóru zde na PDB!

Namísto přímého normování skórů proto normujeme jejich interpretaci.

- Kriteriální (clinical cut-offs, LCA, expektační tabulky, CDM...) – je kategorizovaný přímo atribut (typy), nebo jen jeho interpretace (kritické hodnoty kontinuálního skóru)?
- **Normativní interpretace** (norm-referenced tests) – kvantitativní vyjádření kontinuálního rysu.

Druhy odvozených skórů pro kontinuální atributy:

- Percentilové skóry (percentily, percentilové pořadí, decily, steny a staniny...).
- Standardní skóry (lineárně-transformované vs. normalizované...).
- Vývojové skóry (věkový ekvivalent...).
- Další (např. index relativní výkonnosti, RPI).

Reprezentativita norem

Referenční populace, na kterou zobecňujeme.

- Lokální, místní, národní, mezinárodní...

Reprezentativita vůči referenční populaci.

- Sampling design; kvótní, stratifikované, příležitostné výběry...

Otázka vážení (case weigtening).

Téma norem a reprezentativity je v psychometrice podreprezentované a **mimo hlavní zájem**.

- Sociologie? Ekonomie?
- A vlastně i celé téma norem často částečně chybí v typických učebnicích psychometriky (Furr, 2018).

Pro účely tohoto workshopu předpokládáme, že máme reprezentativní vzorek respondentů vůči cílové populaci, a to (pro zjednodušení) bez potřeby vážení.

Nehomogenní referenční populace

Někdy nechceme vztahovat všechny potenciální respondenty k té samé populaci.

- V těchto případech existuje **významný prediktor výkonu**, který chceme zohlednit.
- Nemodelujeme jen průměrný výkon, ale i variabilitu – potenciálně **heteroskedasticita**.

Typicky demografické proměnné.

- Ale nikoli nutně, může jít i o výkon v jiném testu: rozdílové, diskrepanční, ipsativní skóry...
- Často kombinace: např. diskrepanční skór pro konkrétní věkovou skupinu mužů.

Kategorický prediktor.

- Separátní normy pro různé skupiny (pohlaví, klinické populace...).
- Regresní predikce výkonu na základě demografických charakteristik.

Spojitý prediktor: typicky věkově-specifické normy → možnost kontinuálního normování.

- Spojitá nemusí být přímo naše proměnná, ale jen underlying latentní konstrukt.

Výběrová chyba

Každé normy jsou zatížené klasickou výběrovou chybou.
Lineárně-transformovaný skór:

Standardní chyba průměru:

$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}$$

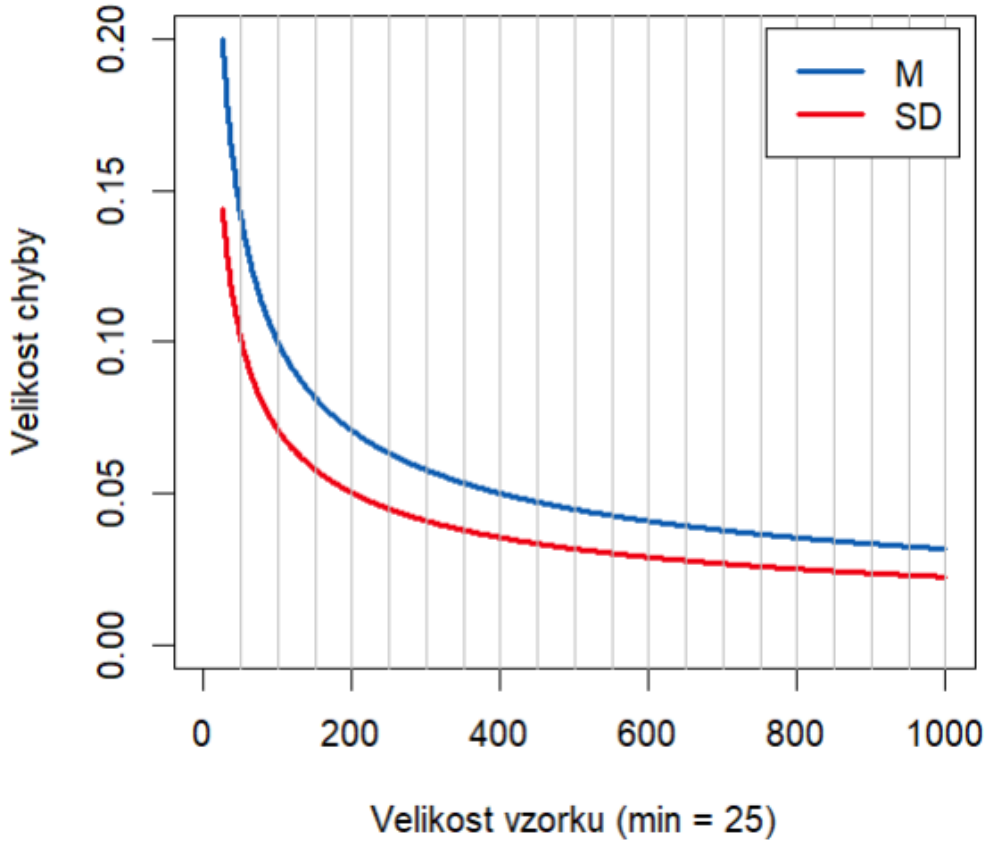
- s – výběrová SD (s $n-1$ ve jmenovateli)
- n – velikost vzorku
- Bez distribučních předpokladů (centrální limitní teorém).

Standardní chyba směrodatné odchylky:

$$\widehat{SE}(s) = \frac{s}{\sqrt{2(n-1)}}$$

- Za předpokladu normálního rozložení.

V případě percentilů: raději simulace!!!



Výběrová chyba: Dopad na normy

Výběrová chyba lineárně-transformovaného skóru:

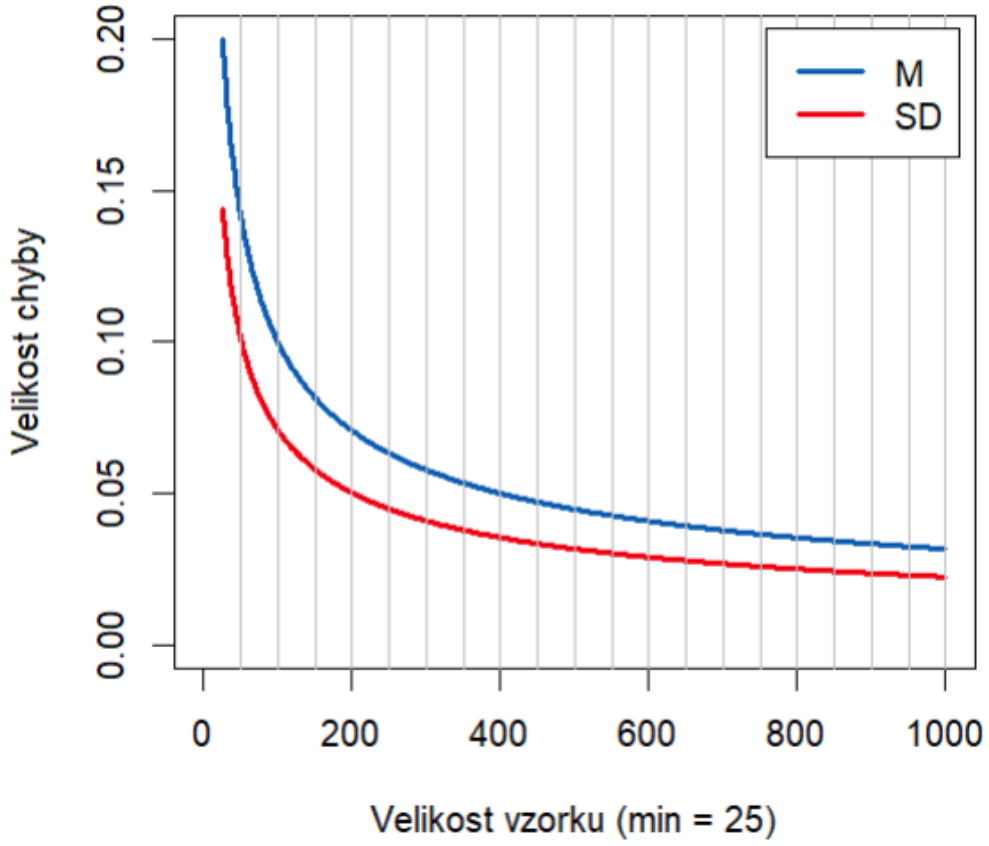
$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}, \qquad \widehat{SE}(s) = \frac{s}{\sqrt{2(n-1)}}$$

Agregovaná chyba konkrétního kvantilu q:

$$\widehat{SE}(q) = \sqrt{\widehat{SE}(\bar{x})^2 + q^2\widehat{SE}(s)^2} = s\sqrt{\frac{1}{n} + \frac{q^2}{2(n-1)}}$$

Roste v extrémech! Pro $s = 1$:

- $\widehat{SE}_{(q=0,n=50)} = .14; \widehat{SE}_{(q=0,n=250)} = .06$
- $\widehat{SE}_{(q=1,n=50)} = .17; \widehat{SE}_{(q=1,n=250)} = .08$
- $\widehat{SE}_{(q=2,n=50)} = .25; \widehat{SE}_{(q=2,n=250)} = .11$
- $\widehat{SE}_{(q=3,n=50)} = .33; \widehat{SE}_{(q=3,n=250)} = .15$



Výběrová chyba: Dopad na normy

Výběrová chyba lineárně-transformovaného skóru:

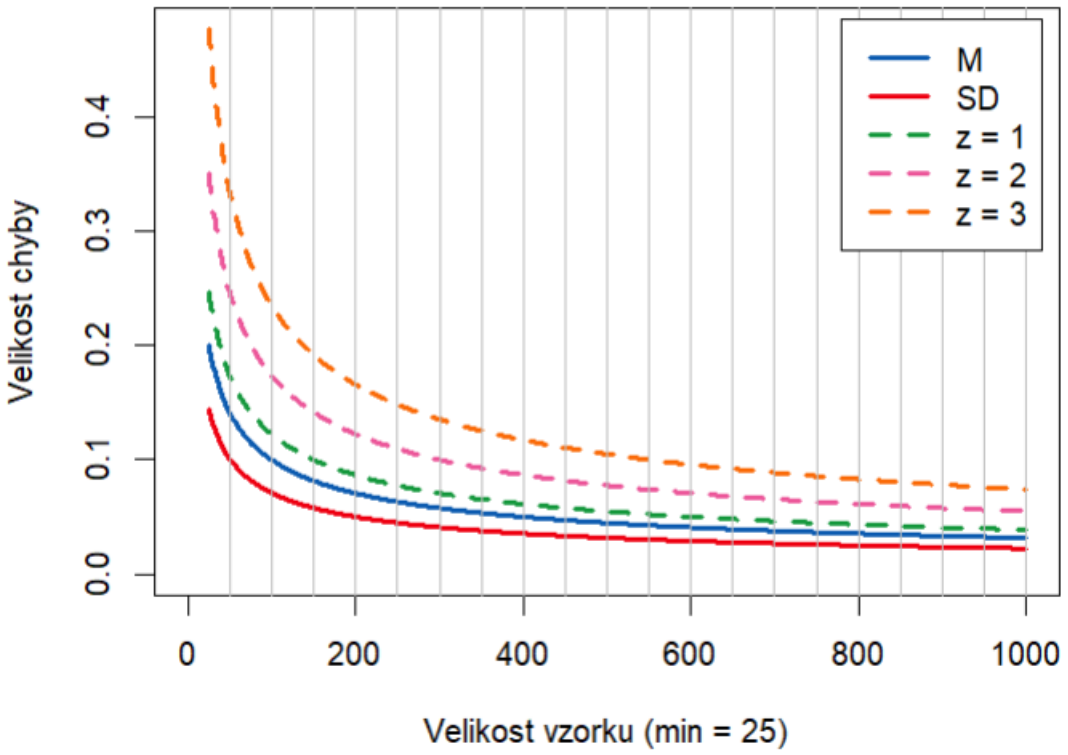
$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}, \qquad \widehat{SE}(s) = \frac{s}{\sqrt{2(n-1)}}$$

Agregovaná chyba konkrétního kvantilu q:

$$\widehat{SE}(q) = \sqrt{\widehat{SE}(\bar{x})^2 + q^2\widehat{SE}(s)^2} = s\sqrt{\frac{1}{n} + \frac{q^2}{2(n-1)}}$$

Roste v extrémech! Pro $s = 1$:

- $\widehat{SE}_{(q=0,n=50)} = .14; \widehat{SE}_{(q=0,n=250)} = .06$
- $\widehat{SE}_{(q=1,n=50)} = .17; \widehat{SE}_{(q=1,n=250)} = .08$
- $\widehat{SE}_{(q=2,n=50)} = .25; \widehat{SE}_{(q=2,n=250)} = .11$
- $\widehat{SE}_{(q=3,n=50)} = .33; \widehat{SE}_{(q=3,n=250)} = .15$



Výběrová chyba: Dopad na interpretaci skóru

Výběrová chyba přidává další šum k běžné chybě měření (SE).

Postup 1: **Teorie zobecnitelnosti** – typicky(!) jen chyba průměru.

- 1fasetový model $p \times I$ + chyba průměru osob ve vzorku, $\bar{p}$:

$$\sigma_\delta^2 = \frac{\sigma_{pi}^2}{N_i} + \left(\frac{\sigma_p^2}{N_p} + \frac{\sigma_{pi}^2}{N_p N_i} \right)$$

- N_i – počet položek v testu
- N_p – počet osob v normativní studii

Postup 2: **Agregace standardní chyby měření SE a standardní chyby odhadu kvantilu $SE(q)$**:

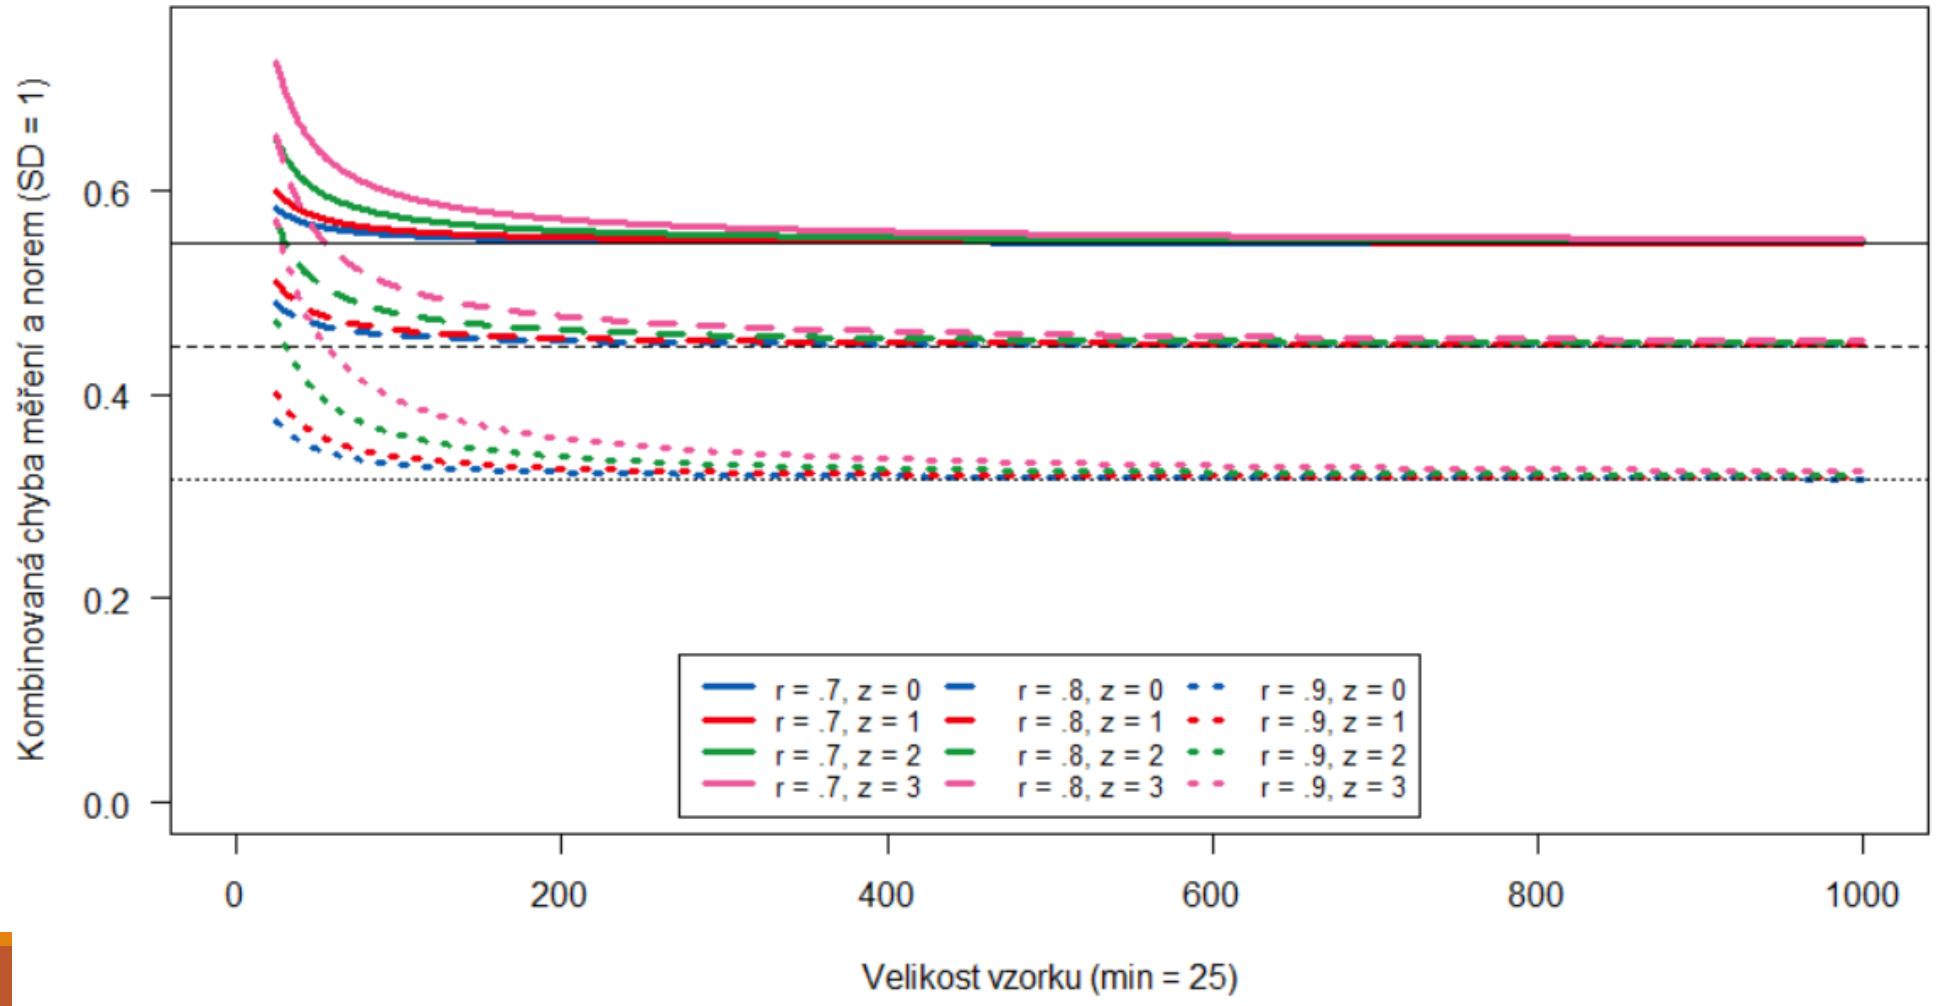
$$SE_{comb}(q) = \sqrt{SE_x^2 + SE(q)^2} = s\sqrt{(1 - r_{xx'}) + \frac{1}{n} + \frac{q^2}{2(n-1)}}$$

Vliv výběrové chyby norem:

- Po agregaci s chybou měření nečekaně slabý!
- Klesá s rostoucím N a roste s extremitou skóru.
- Jen málo (a nehomogenně) je závislý na reliabilitě.

s = 1	SE	n= 50	n= 250	n= 1000
r=.7, x=0	.55	.57 (.14)	.55	.55
r=.7, x=1	.55	.57	.55	.55
r=.7, x=2	.55	.60	.56	.55
r=.7, x=3	.55	.64	.57	.55
r=.9, x=0	.32	.35	.32	.32
r=.9, x=1	.32	.36	.33	.32
r=.9, x=2	.32	.40	.33	.32
r=.9, x=3	.32	.46	.35	.32

Výběrová chyba: Dopad na interpretaci skóru



Normalizace skórů a percentily

Interpretace standardních skórů vyžaduje normální rozložení.

- Neplatí samozřejmě pro percentily.

Potřeba normalizace nenormálně rozložených skórů, nebo použití percentilu.

Percentily ale svádí k interpretačním chybám – **APA doporučuje T-skóry** (resp. IQ).

- Škála není lineární, jednotky představují rozdílnou míru výkonu.
- Svádí k nadhodnocení rozdílů u průměru, podhodnocení rozdílů v extrémech.
- Nelze s nimi dále analyticky pracovat (sčítat, použít v analýzách).
- Součet percentilů není percentil.
- Snadná záměna s procentuální správnosti.
- Na první pohled intuitivní, korektní interpretace ale náročná.

Normalizace skórů: parametricky

Parametrická transformace (logaritmizování, odmocnění).

- Jen v opodstatněných případech (např. reakční časy).

Normalizace podle průměru nebo mediánu (např. WJ-IV$_{US}$).

- Výpočet specifické SD pro nad/podprůměrné: $s_- = \sqrt{\frac{2\sum_{x_i<\bar{x}}(x_i-\bar{x})^2}{2n_- - 1}}$, $s_+ = \sqrt{\frac{2\sum_{x_i>\bar{x}}(x_i-\bar{x})^2}{2n_+ - 1}}$.
- Výpočet standardního skóre s použitým příslušné směrodatné odchylky.

Výhodou parametrických postupů je, že lze **stejným způsobem transformovat i chybu měření**.

- V případě parametrické transformace nicméně dochází k změně její distribuce!
  - Lze zanedbat nebo použít výslednou distribuci – např. pro logaritmované skóry log-normální rozdělení.
- V případě normalizace podle průměru/mediánu pozor na CI zahrnující průměr!
  - Je potřeba „seskládat“ dohromady.

Normalizace skórů: neparametricky

McCallova plošná transformace.

- Skór je převeden na percentil a ten je následně převeden na příslušný kvantil cílové jednotky.
- Zatíženo velmi obtížně parametrizovatelnou chybou odhadu percentilu.

Jiné nelineární transformace.

- Např. Taylorovy polynomy, obsah tohoto workshopu, nebo GAMLSS.
- Chybu normalizace je zpravidla nutné simulovat.

V těchto případech **není snadné odhadnout výslednou chybu měření po transformaci**.
Správný postup konstrukce CI:

- 1. Odhad intervalu spolehlivosti pro hrubé skóre.
- 2. Teprve tento interval transformovat společně s bodovým odhadem.

Dokud je ale transformace monotónní a bijektivní, neovlivňuje reliabilitu!

Normy jako funkce

V případě běžných norem závislých na věku jsou normy funkcí věku (a) a hrubého skóru (x):

$$S_{norm} = f(x, a)$$

Tato funkce může mít různou podobu a lze uvažovat i specifické funkce jedné z proměnných:

- **Pro konkrétní věk vertikální funkce:**
  - a_k: $f_{a_k}(x) \coloneqq f(x, a_k)$ – např. $7 \leq a_k < 8$leté děti.
- **Pro konkrétní HS horizontální funkce:**
  - x_l: $f_{x_l}(a) \coloneqq f(x_l, a)$ – např. 10 bodů; inverzní funkce pak např. IQ 70 nebo 90. percentil.

Na tyto dílčí funkce typicky klademe nějaké zjevné požadavky:

- Ideálně minimalizace výběrové chyby.
- „Plynulost“, resp. regularita ($f \in C^1$)
- Spojitost, po celém definičním oboru (či jeho části) monotónicita (minimálně vertikálně).
  - Např. všechny $f_{x_l}(a)$ by v dětství měly být monotónní klesající (u starších dětí stejný hrubý skór → nižší standardní skór).
  - Žádné $f_{x_l}(a)$ by se neměly křížit; důsledek monotónních $f_{a_k}(x)$, tedy vyšší hrubý skór → vyšší standardní skór.

Potřeba horizontálního vyhlazení

Jakákoli transformace na odvozený skór **v každé věkové kohortě odděleně** (separátní konstrukce vertikálních funkcí $f_{a_k}(x)$) vyžaduje diskretizaci jinak spojitého věku. Důsledek:

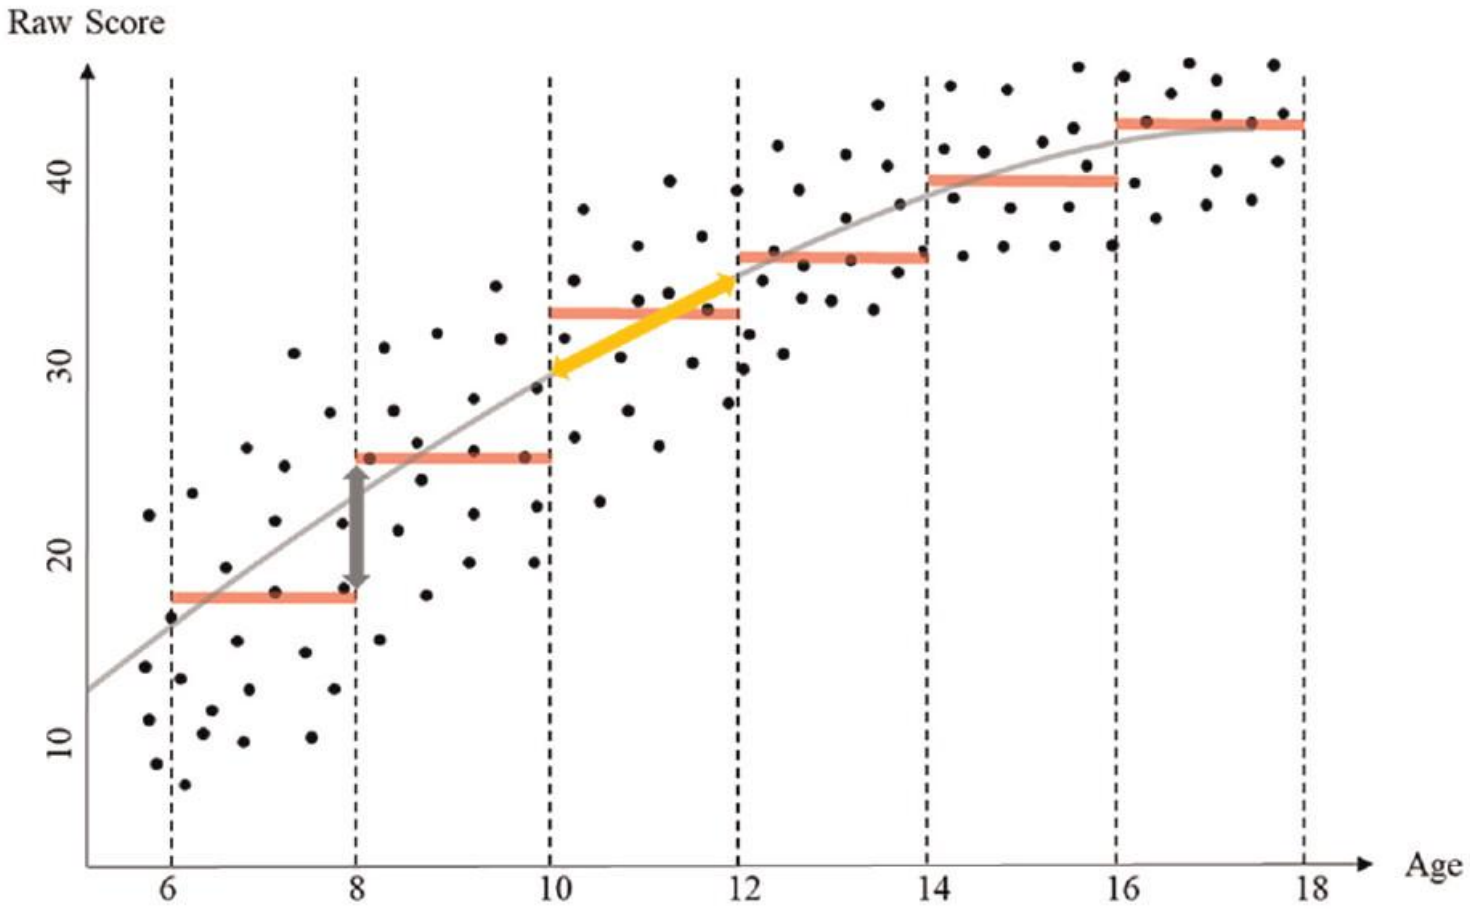
Horizontální funkce $f_{x_l}(a)$ není spojitá: konstantní uvnitř kohort, na hranicích schodovitá.

- To zvyšuje normativní chybu vůči původní kontinuální proměnné věku, a to zejm. v oblasti hranic kohort a rychle se měnících rysů.
- V důsledku výběrové chyby parametrů vertikálních funkcí $f_{a_k}(x)$ a částečně i výběrové chyby průměrného věku $\bar{a}_k$ dané kohorty není funkce regulární – není plynulá, hladká, spojitá.
- Není monotónní tam, kde bychom to čekali – nutnost ručních úprav.

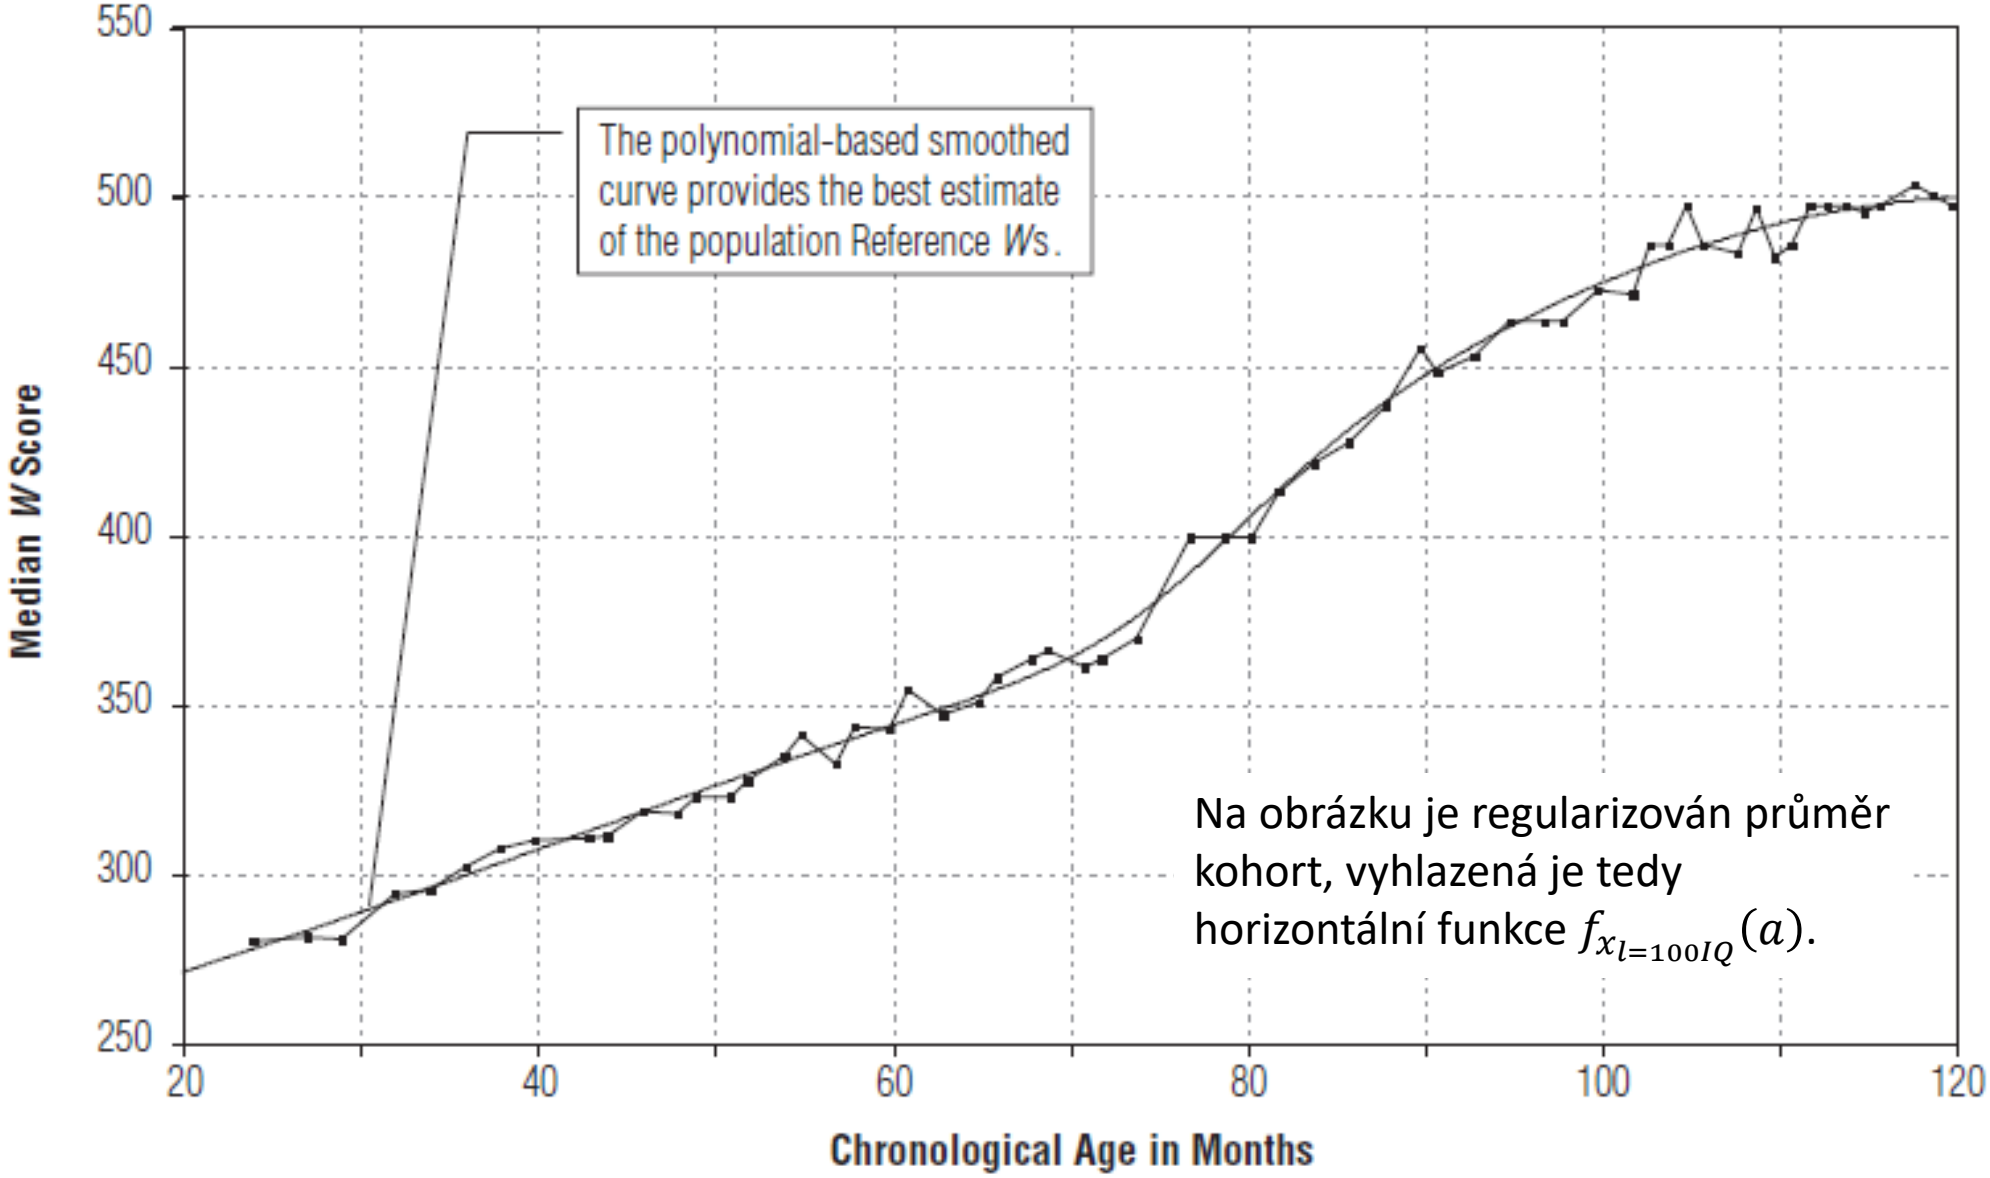
Řešení: Horizontální vyhlazení (regularizace horizontálních funkcí $f_{x_l}(a)$).

- Stejných skórů napříč věkem, resp. parametrů vertikální funkce napříč kohortami.

Potřeba horizontálního vyhlazení



https://doi.org/10.1177/10731911241260545

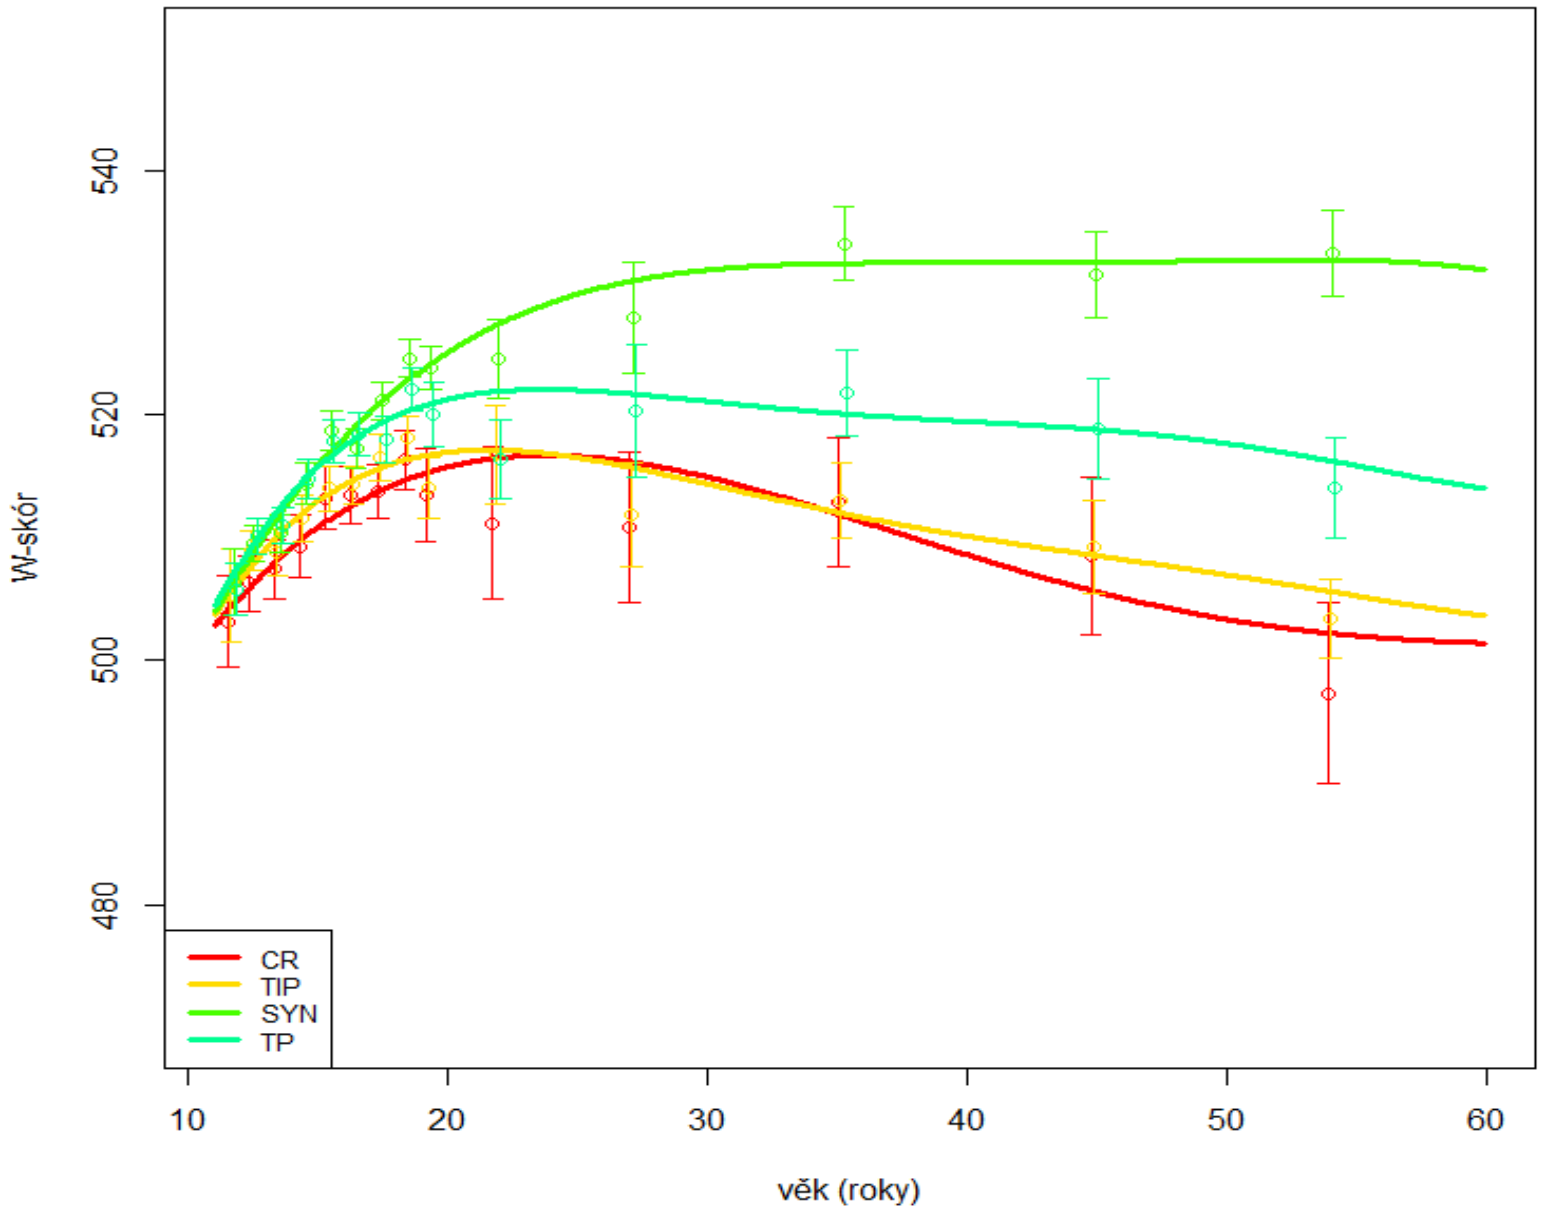


Na obrázku je regularizován průměr kohort, vyhlazená je tedy horizontální funkce $f_{x_{l=100IQ}}(a)$.

Note. A similar process is completed with the standard deviations (*SD*s) for Letter-Word Identification.

Technický manuál WJ-IV

Cígler et al. (2017)
Krátký inteligenční test



Potřeba vertikálního vyhlazení

Standardní skóry nelze interpretovat, pokud jsou výrazně nenormálně rozložené.

Standardní postup plošné transformace má ale znatelnou **výběrovou chybu, zejm. v extrémech**.

- Distribuce malých vzorků je navíc méně centrální (Studentovo t-rozložení) – systematická chyba.
- Což dále umocňuje potíže potíže s neregularitou horizontální funkce $f_{x_l}(a)$.
- A dále také zvyšuje výběrovou chybu norem.

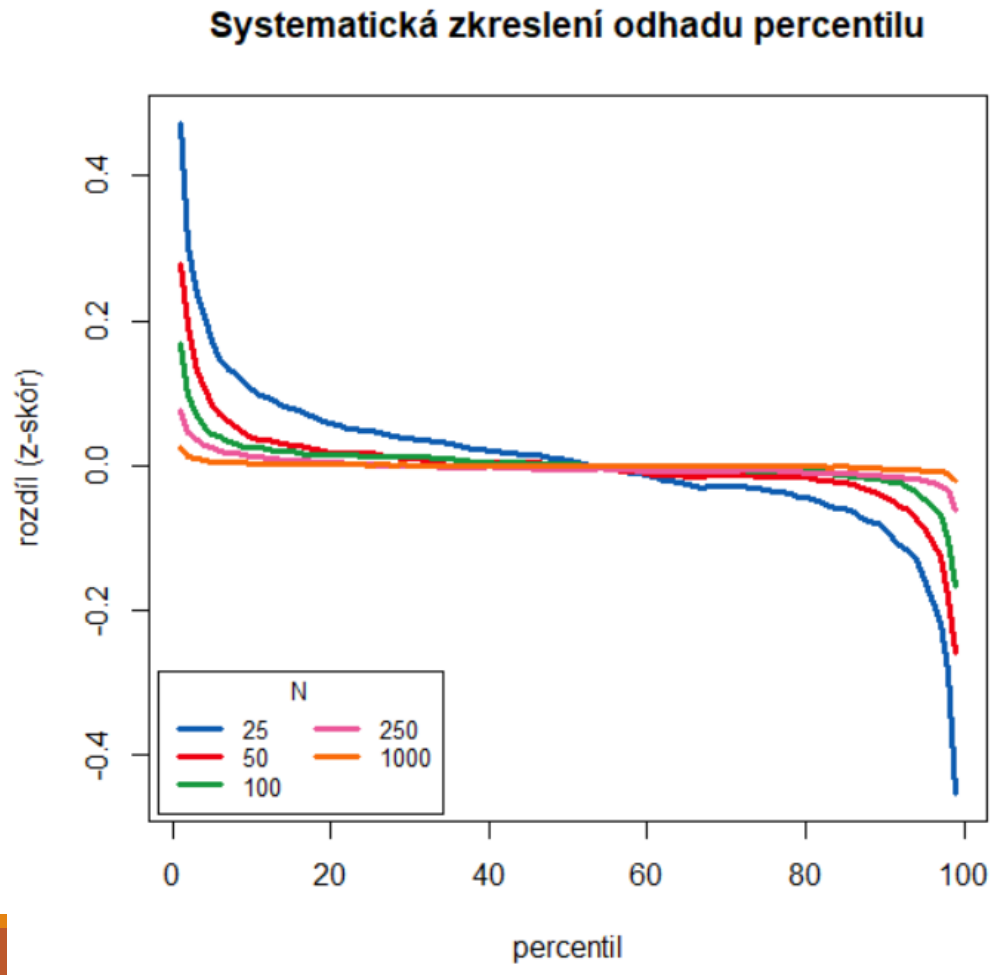
Kromě toho je kumulativní distribuční funkce nutná pro tvorbu percentilu „**schodovitá**“.

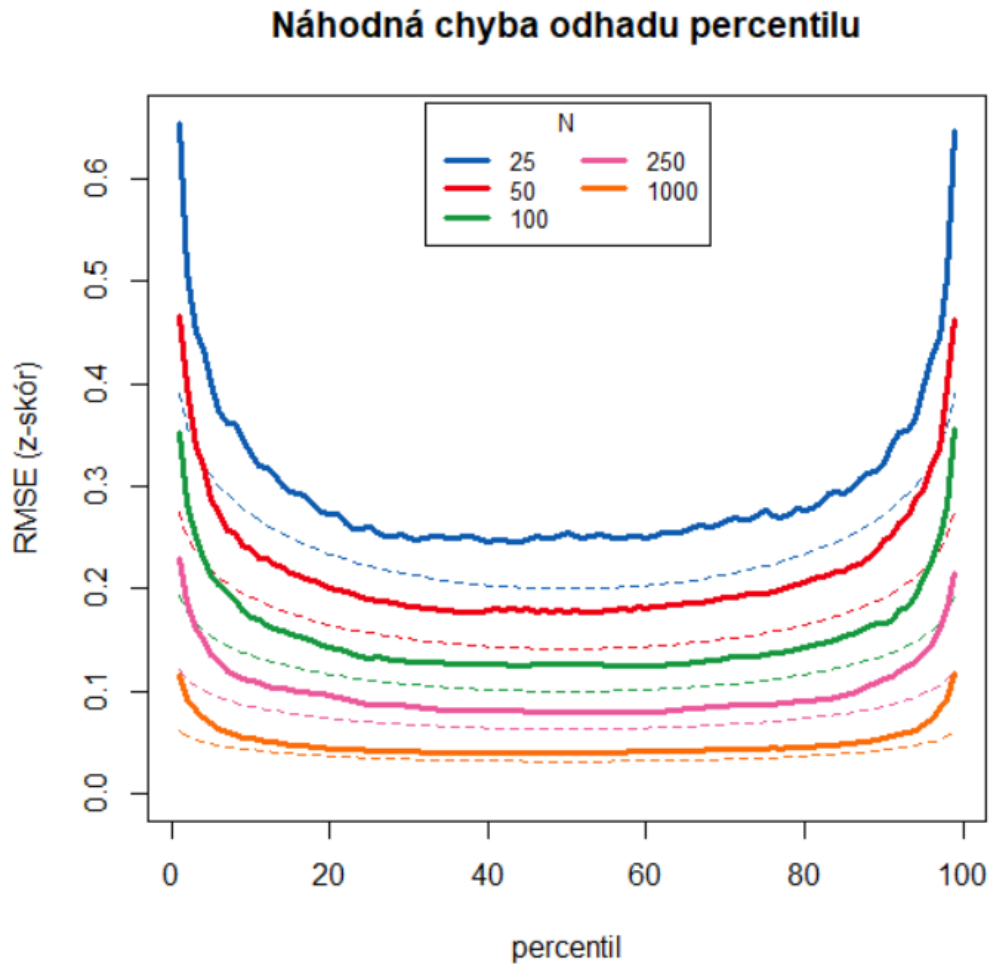
Řešením je vyhlazení vertikální funkce $f_{a_k}(x)$ – tedy její regularizace.

- V případě lineárně-transformovaných standardních skórů je $f_{a_k}(x)$ přirozeně regularizovaná!
- Jsou-li tedy hrubé skóry normálně rozložené, je jednoznačně výhodné použít lineární transformaci.
  - V případě cNORM jen polynom prvního řádu pro lokaci, k = 1.
- Další výhoda (nevýhoda?) lineární transformace: aproximace mimo pozorované skóry vzorku.

Chyba odhadu percentilu

(Za předpokladu normálního rozložení, 1000 náhodných vzorků)





Chyba odhadu obecně

Chyby popsané výše jsou ideální, spodní hranicí výběrové chyby.

- Nad simulovanými nebo dobře fungujícími daty.

Reálná normativní data nenáhodných výběrů jsou zašuměná, schodovitá, malá...

- Na nenáhodných vzorcích vznikají systematické výběrové chyby.

Počítejte s tím, že normativní chyba je vždy mnohem větší.

Ideální, velké a náhodně vybrané vzorky je ale těžké zajistit.

- Zajistit co největší variabilitu příležitostného výběru.
- Hodně různých sběračů, heterogenní nábor respondentů... chyby se „vyruší“?

Samostatné vertikální vyhlazení

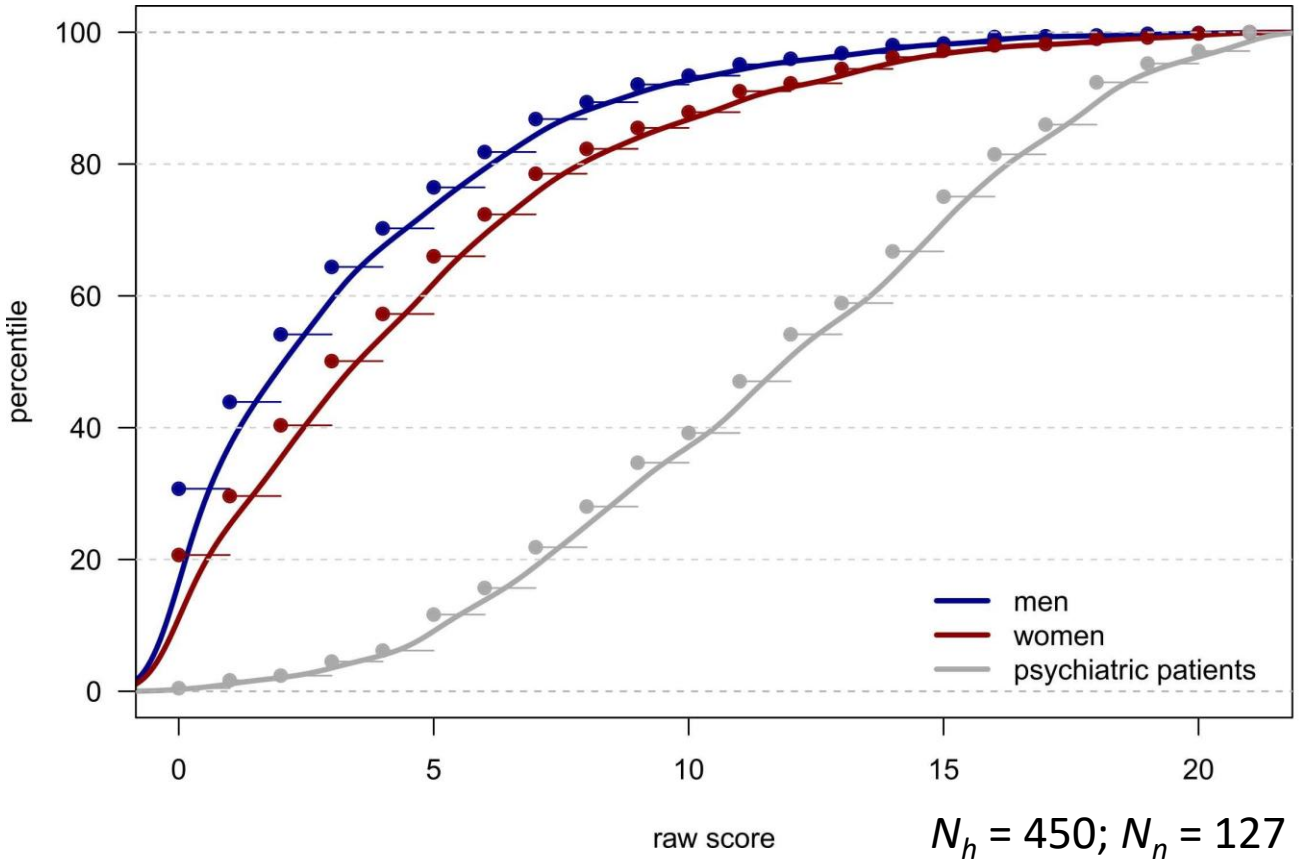
Pokud je jen jediná kohorta nebo neexistuje spojitý prediktor a je realizovaná plošná transformace, samostatné vertikální vyhlazení je jednoduché.

Optimální postup: Kernelovská kumulativní distribuční funkce (KCD).

- Proloží „schodovité“ percentily regularizovanou distribuční funkcí.

Neodstraní plochost malého vzorku!

Nejjednodušší implementace: `ks::kcde`.



N_h = 450; N_n = 127

GAD-7 (Cígler et al., 2026): https://doi.org/10.1016/j.janxdis.2026.103149

Přehled postupů kontinuálního normování

Přehled postupů

Urban, J., Scherrer, V., Strobel, A., & Preckel, F. (2025). Continuous Norming Approaches: A Systematic Review and Real Data Example. *Assessment, 32*(5), 654-674. https://doi.org/10.1177/10731911241260545

- Vyhlazení skupinových charakteristik (**inferential norming**) – průměr, směrodatná odchylka.
- **Regresní normy** (**simplified parametric norming**).
- Distribuční regrese, typicky GAMLSS (**parametric norming**).
  - Případně též Box-Cox LMS transformace.
- **Semiparametrické normy pomocí Taylorových polynomů (cNORM).**

Další postupy:

- Kvantilová regrese – přímé regresní modelování hranic kvantilů v závislosti na věku (funkcí $f_{x_l}(a)$).
- Kontinuální normy **založené na IRT** s věkově-podmíněnou distribucí latentního rysu.
  - Tohle je můj nový favorit!

Přehled postupů

Jsou ale cNORM opravdu nejlepším postupem?

- Jsou rozhodně lepší než diskrétní normy (Urban et al., 2025; Heister et al., 2024).
- Jsou rozhodně lepší než zjednodušené regresní normy.
- Naopak IRT-based postupy mohou být lepší (Heister et al., 2024) a logicky to dává smysl.
- Parametrické GAMLSS normy v simulačních studiích vycházejí nepřekvapivě nepatrně lépe.
- Parametrické postupy v cNORM se zdají být ale velmi slibné!
  - Nemám s nimi praktickou zkušenost při standardizaci.

Regresní normy

Používané zejména v klinické psychologii a neuropsychologii.

Regresní model: závislá proměnná je HS, prediktory věk či další demografie (např. vzdělání).

- Vztah může být i kvadratický či složitější.

1. Odhad očekávaného výkonu $\hat{X}_i$ osoby i s danou kombinací charakteristik (zde jen věk a_i):

$$\hat{X}_i = \hat{\beta}_0 + \hat{\beta}_1 a_i$$

2. Standardní skóre je pak odhadnuto s pomocí směrodatné odchylky reziduí s_e:

$$\hat{z}_i = \frac{X_i - \hat{X}_i}{s_e}$$

Extrémně jednoduchý postup, ale silné předpoklady, zejména:

- homoskedasticita, adekvátnost lineárního modelu (lineární, kvadratický... polynomický vztah).
- Dodatečně normalita reziduí!!!
- Neomezený definiční obor (žádné efekty stropu či podlahy).

Regresní normy

Existuje více rozšiřujících variant.

Normalizace před regresí.

- Např. plošná transformace.
- Obsahuje jiné silné předpoklady.

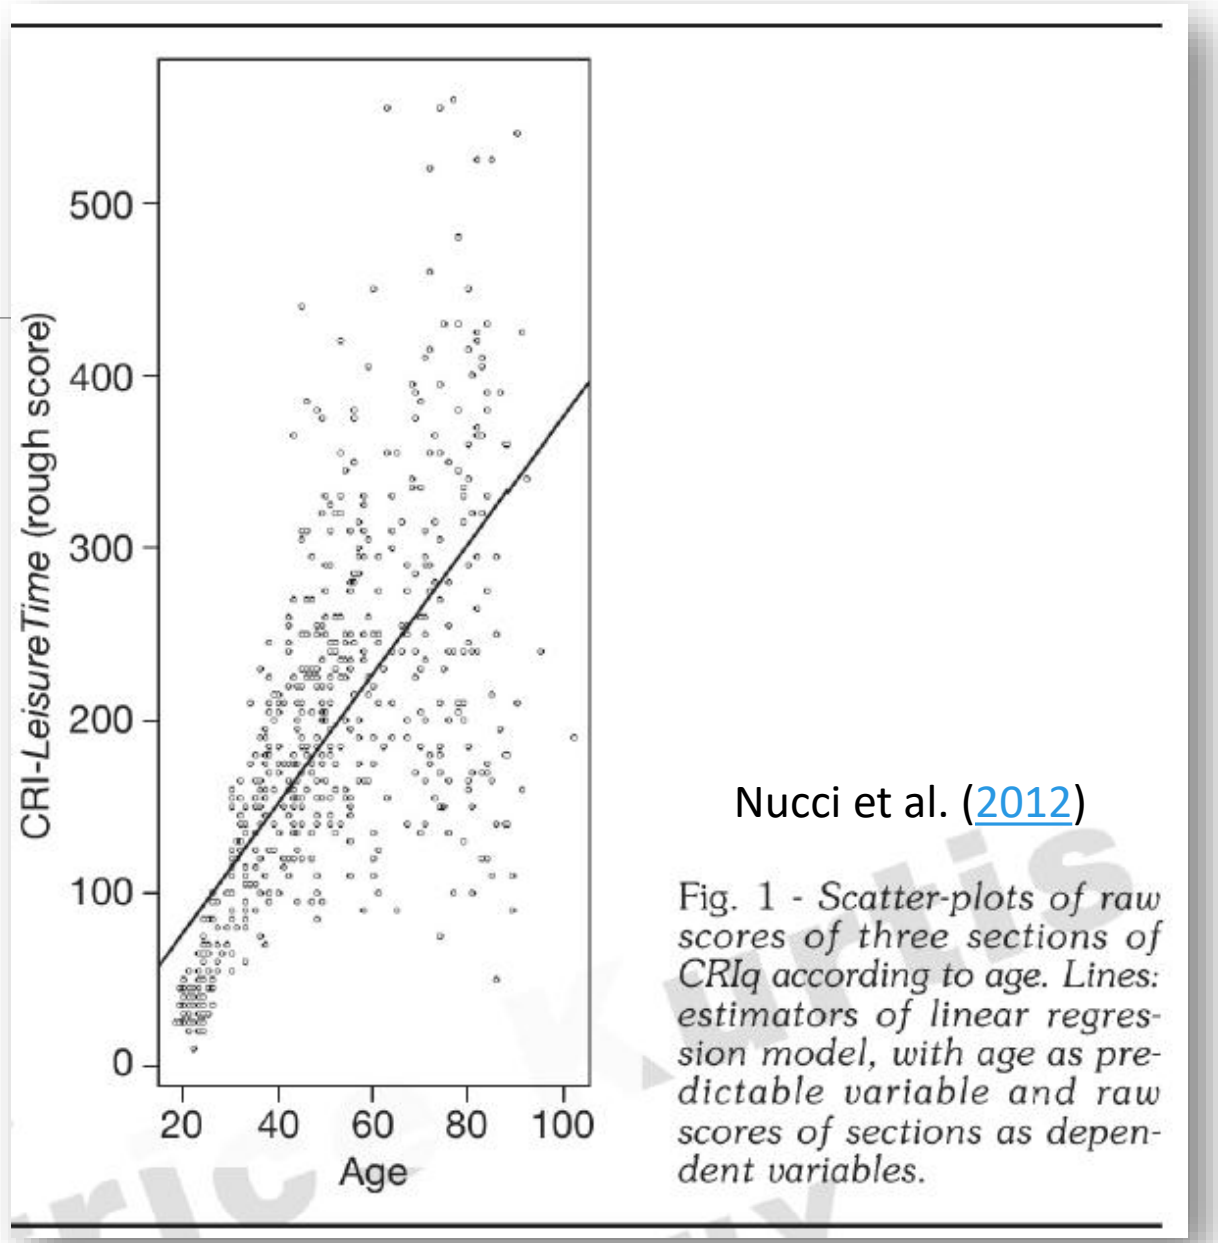
Generalized Additive Models for Location, Scale, and Shape (GAMLSS)

- Rigby & Stasinopoulos (2005)

Robustní regrese.

- Částečně řeší heteroskedasticitu.

Žádná z variant ale není univerzální a bezpečná.



Nucci et al. (2012)

Fig. 1 - *Scatter-plots of raw scores of three sections of CRIq according to age. Lines: estimators of linear regression model, with age as predictable variable and raw scores of sections as dependent variables.*

Inferenční normy
Horizontální vyhlazení parametrů lineární transformace

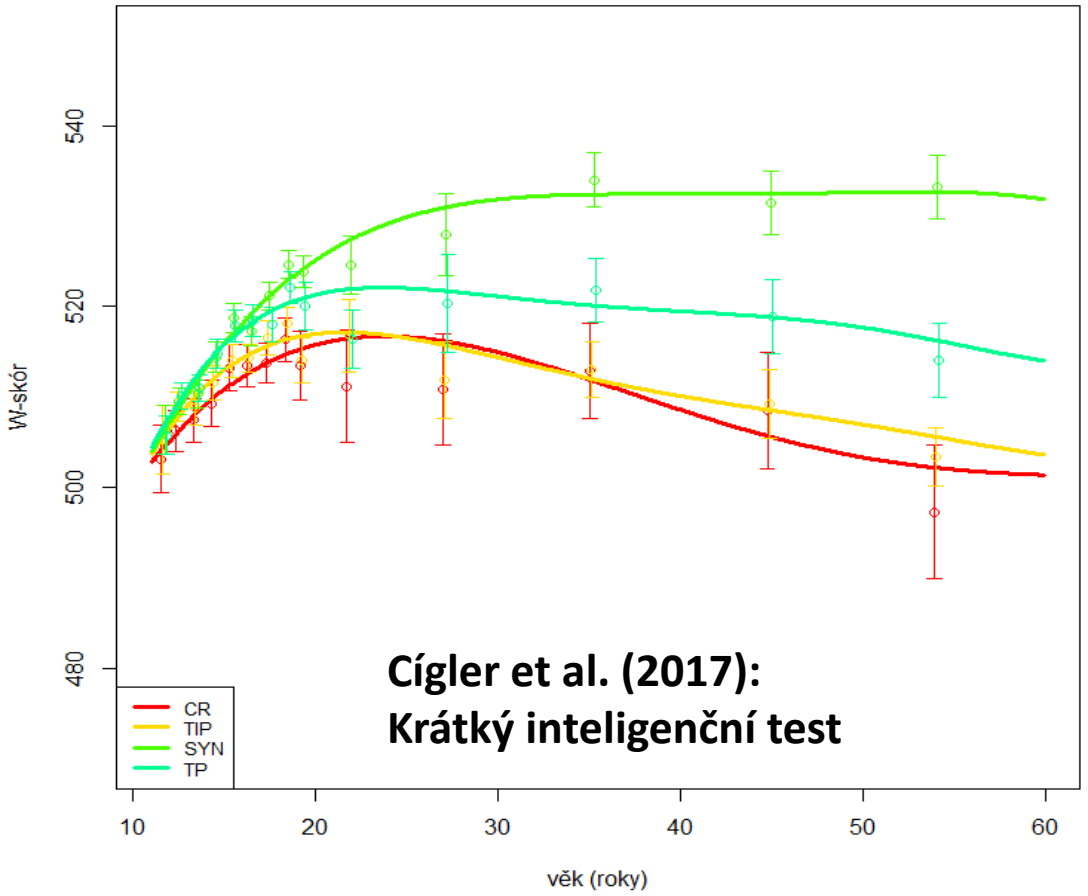
Odhad parametrů pro lineární transformaci pro každou kohortu zvlášť.

- Přinejmenším průměr ($\hat{x}_{a_k}$) a směrodatná odchylka ($\hat{s}_{a_k}$), případně obě směrodatné odchylku po rozdělení dle průměru ($\hat{s}_{-a_k}$, $\hat{s}_{+a_k}$).

Parametry jsou následně proloženy polynomickou regresí, loess, spline apod.

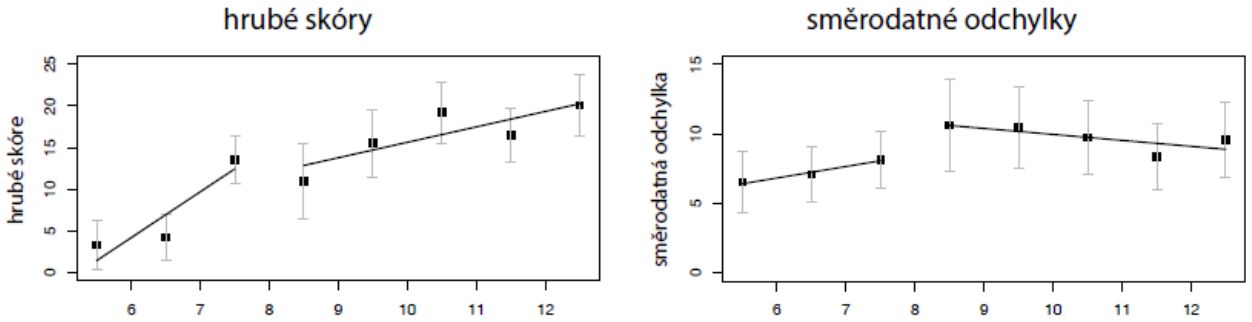
Lineární transformace garantuje vertikálně hladké skóry ($f_{a_k}(x)$).

Vyhlazení parametrů v kombinaci s lineární transformací zajistí horizontální vyhlazení pro všechny přípustné hrubé skóry ($f_{x_l}(a)$).

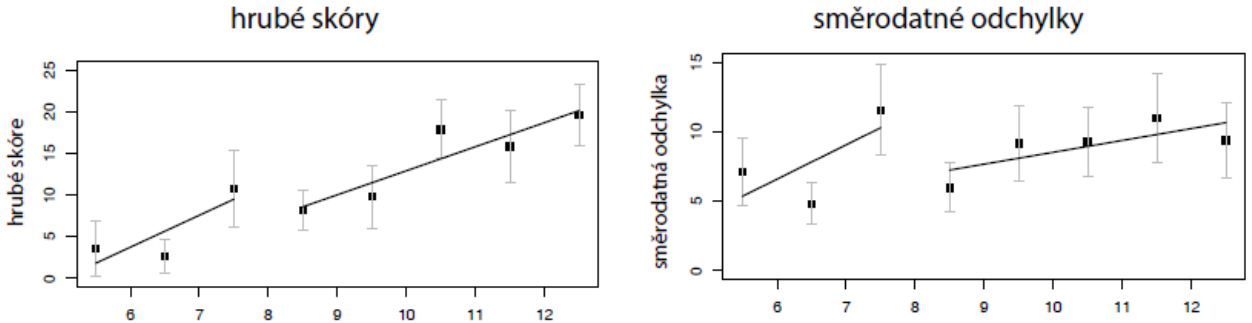


Inferenční normy
Horizontální vyhlazení parametrů lineární transformace

obr. 17: **Vývoj průměrů a směrodatných odchylek hrubého skóre podle věku u dívek – regresní odhad a bodové odhady pro jednotlivé věkové skupiny vč. 95% int. spolehlivosti**



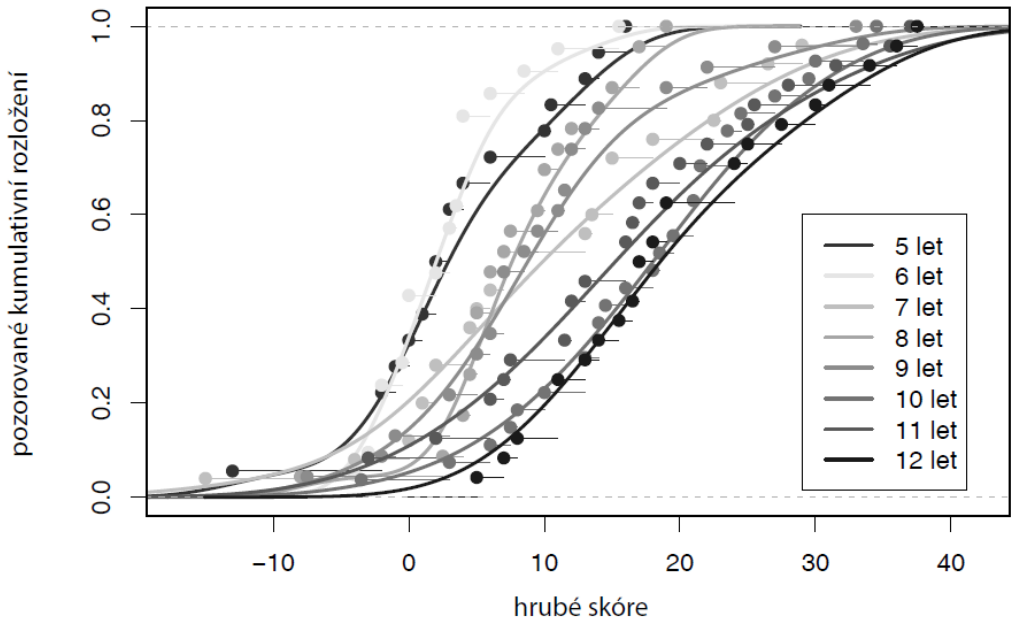
obr. 18: **Vývoj průměrů a směrodatných odchylek hrubého skóre podle věku u chlapců – regresní odhad a bodové odhady pro jednotlivé věkové skupiny vč. 95% int. spolehlivosti**



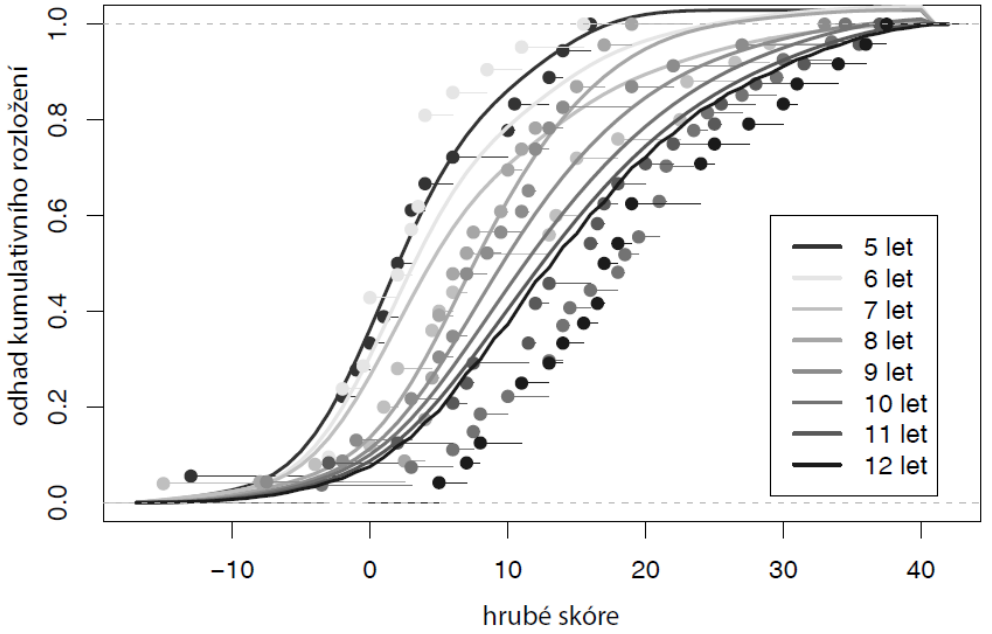
Test vyprávění příběhů (Cígler a Durmeková, 2017)

Multivariační kernel-smoothing
Vyhlazená sdílená multivariační kumulativní pravděpodobnost

obr. 20: **Pozorované kumulativní rozložení hrubého skóre chlapců podle věkových skupin**
(viz též barevná příloha, s. 79)



obr. 22: **„Vyhlazený" odhad kumulativního rozložení pro chlapce napříč věkovými skupinami**
(viz též barevná příloha, s. 80)



Test vyprávění příběhů (Cígler a Durmeková, 2017)
Prostřednictvím knihovny ks jako P(a,b) = P(A≤a)∩P(B≤b). Zpětně lze odhadnout P(b|a) pro konkrétní hrubý skór „b": P(b|a) = P(a,b)/P(A≤a). Nemyslím, že to fungovalo dobře...

cNORM

Semiparametrické kontinuální normy

cNORM

Primární autoři balíčku: Lenhard, Lenhard, & Gary (2018)

Semiparametrický přístup, který souběžně realizuje vertikální i horizontální vyhlazení bez distribučních předpokladů.

- Taylorovy polynomy aproximují hodnoty funkce jednodušším polynomem bez distribučních předpokladů.

cNORM balíček nedávno implementoval i vážení respondentů.

Od roku 2024 nabízí cNORM i parametrické modelování s distribučními přepodklady.

- beta-binomický model pro silové testy s hrubým skóre
- CMP (Conway-Maxwell-Poisson Distribution) pro rychlostní testy (počet úloh za čas)
- SHASH (Sinh-Arcsinh Distribution) pro obecné spojité skóry (parametry analogické M, SD, Sk, K).
  - Tohle je typicky podobné GAMLSS.

Postup s Taylorovými polynomy

1. Rozdělení vzorku na kohorty, v každé provizorní odhad klasického percentilového skóru (l) a průměrného věku (a).

2. Vytvoření Taylorových polynomů ($a^1, a^2, \dots, a^T$ a $l^1, l^2, \dots, l^K$) a jejich interakcí ($a^1 l^1, a^1 l^2, \dots, a^1 l^k, a^2 l^1, \dots, a^k l^k$); typicky $K \leq T \leq 4$.

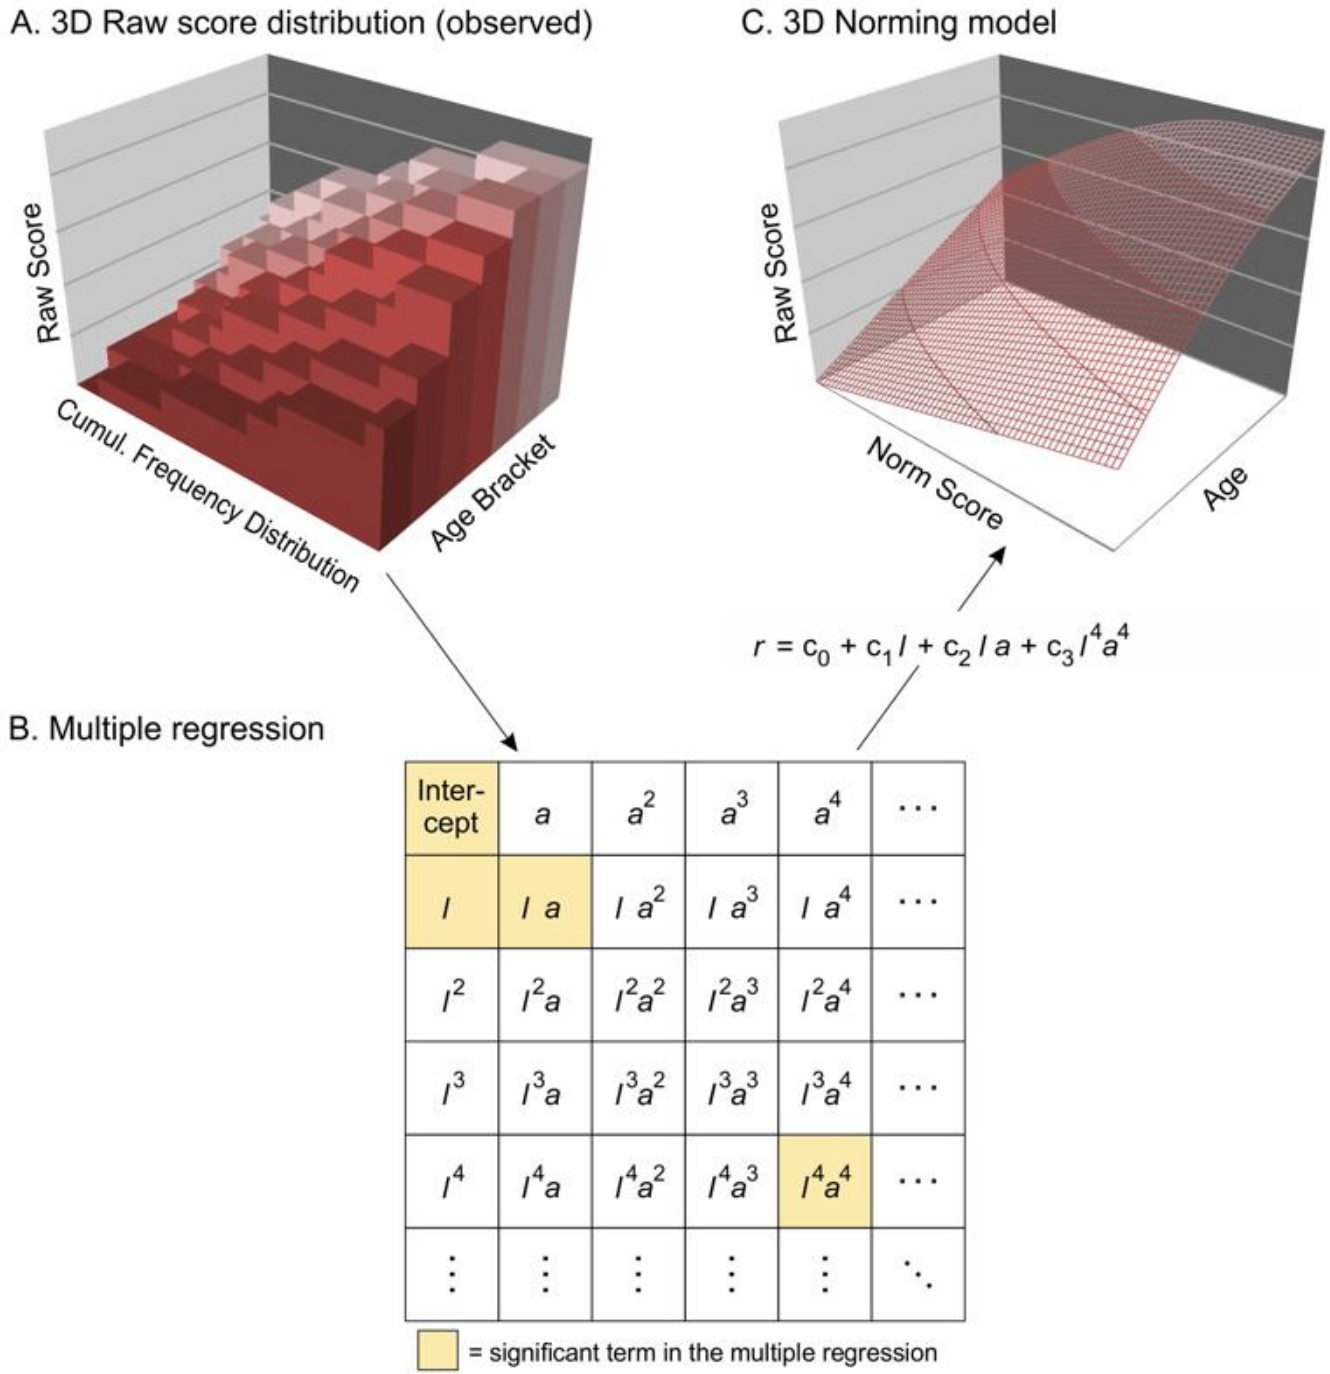
3. Odhad série regresních modelů predikujících hrubý skór x:

$$x \approx f(l, a) = \sum_{k=0}^{K} \sum_{t=0}^{T} \beta_{k,t} \cdot l^k \cdot a^t + e$$

- $f(l, a)$ je normovací funkce standardního skóru l a věku a, její hodnotou je pozorované skóre x.
- Všimněte si, že je zde opačná logika než u dříve představených funkcí $f(x, a)$, závislou je hrubý skór!
  - Ryze arbitrární volba; vlastně si nejsem zcela jistý, proč přesně.

4. Výběr nejlepšího modelu (cross-validace a další postupy).

5. Model použit pro zpětnou predikci standardního skóre (l) z věku (a) a pozorovaného skóru (x).


A. 3D Raw score distribution (observed)
Raw Score
Cumul. Frequency Distribution
Age Bracket
C. 3D Norming model
Raw Score
Norm Score
Age
$r = c_0 + c_1 l + c_2 l a + c_3 l^4 a^4$
B. Multiple regression
Inter-cept
a
a^2
a^3
a^4
l
$l\ a$
$l\ a^2$
$l\ a^3$
$l\ a^4$
l^2
l^2a
l^2a^2
l^2a^3
l^2a^4
l^3
l^3a
l^3a^2
l^3a^3
l^3a^4
l^4
l^4a
l^4a^2
l^4a^3
l^4a^4
= significant term in the multiple regression

cNORM: Postup s Taylorovými polynomy

Významná úspora parametrů.

- Diskrétní lineárně-transformované normy pro respondenty 5–20 let: 2×16 = 32 parametrů!
- cNORM – typicky jen pět až šest (byť silně kolineárních) parametrů.
  - Kolinearita nám nevadí – podstatný je průběh predikce a koeficient determinace, ne hodnota prediktorů.

Značné riziko over-fittingu – nutnost cross-validace!

- Neplauzibilní průběh kvantilů.

Velikost vzorku (klinická zkušenost HC):

- mnoho malých skupin – špatné fungování norem v extrémech, lepší okolo průměru
- málo velkých skupin – horší vyhlazení okolo průměru, ale lepší fungování v extrémech

Porušení vertikální monotonicity – nutnost „omezení“ skórů.

- „Zkřížení kvantilů“.

- CMP = Conway-Maxwell-Poisson Distribution
- SHASH = Sinh-Arcsinh Distribution

Parametrické varianty

	Distribution-free (Taylor)	Beta-binomial	CMP	SHASH
Score scale	Continuous or discrete	Integer, $0 \leq y \leq n$	Integer, $y \geq 0$	Continuous, $y \in \mathbb{R}$
Typical tests	General ability and achievement	Power and accuracy tests	Speeded tests, rate tasks	Continuous measures, response times
Upper bound	Post-hoc clipping to $[minRaw, maxRaw]$	Natural bound (n items)	Open-ended, or truncated via `max_score`	None
Distributional shape	Any (empirical)	Binomial with beta mixing	Over-, equi- or under-dispersed	Skewed, light or heavy tails
Main strength	Maximum flexibility	Respects fixed item numbers	Models the dispersion directly	Handles negative and uncentred scores
Function	`cnorm()`	`cnorm.betabinomial()`	`cnorm.cmp()`	`cnorm.shash()`

Parametrické postupy

Všechny distribuce mají 2–4 parametry, kterými je modelováno přímo rozložení hrubého skóru jako funkce věku. Z toho pak lze odvodit kumulativní distribuční funkce.

- Díky tomu není nutné respondenty rozdělit prvně do skupin a odhadnout provizorní normy.
- Všechny parametry (případně jejich logaritmus pro zajištění pozitivity) jsou vždy modelovány polynomickou regresí jako funkce věku.

Beta-binomické rozložení.

- Určené pro součet binárních položek ($0 < X < n$, kde n je počet položek).

Conway-Maxwell-Poisson Distribution (CMP).

- Rychlostní testů, kde počtem bodů je počet položek zvládnutých v časovém limitu ($0 < X$).
- Umožňuje modelovat under/over disperzi.
- Při maximální počtu položek se použije ořezaná distribuce.

Sinh-Arcsinh Distribution (SHASH)

- Čtyři parametry (podobné 4 momentům, tedy průměru, SD, zešikmení a špičatosti).
- Vždy možnost vertikální extrapolace (na rozdíl od Taylorových polynomů).

Závěrem úvodu

Primárně mluvím o cNORM s Taylorovými polynomy.

Ale není to jediný a ani ideální postup – parametrické možnosti mohou fungovat lépe, zejména na malých datech.

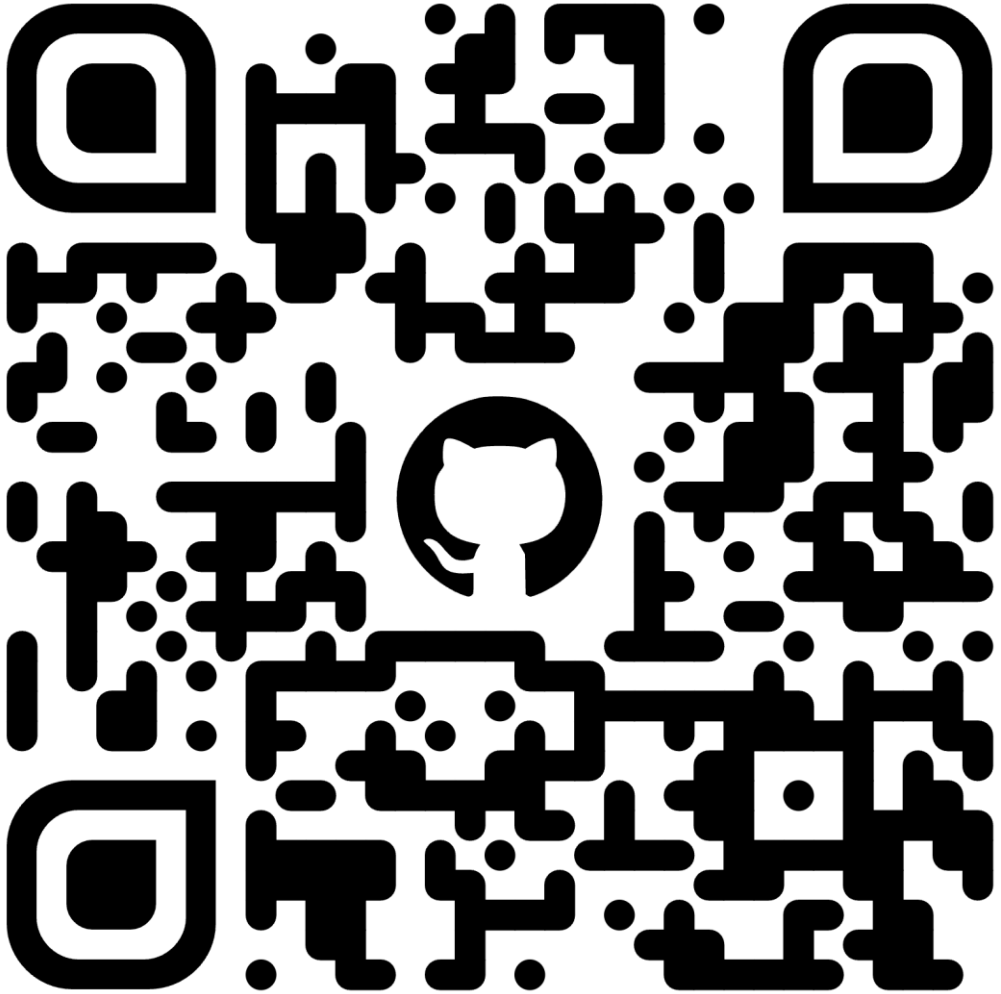
Take-home message:

Jakékoli kontinuální normy (snad vyjma prostých regresních) jsou lepší než diskrétní normy.

Konkrétní design je nutné volit s ohledem na data.

Pojďme si to vyzkoušet!

Veškeré materiály, podklady, skripty a cvičná data jsou k dispozici na GitHubu.



https://github.com/hynekcigler/cnorm_workshop

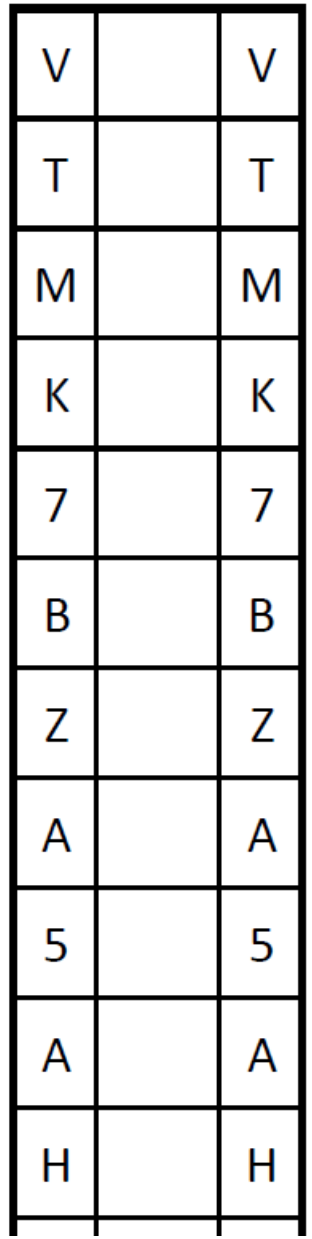
Praktická ukázka

T01: Test Grafomotorického tempa. Prostý přepis tří sloupců znaků.

- Test je parametrizován pomocí log-normálního IRT modelu (viz samostatná přednáška na PDB), hrubým skórem je M-skór – 10leté děti mají M = 0.

Témata:

- Různý počet skupin, funkce rankBySlidingWindow().
- Různý počet parametrů, příliš jednoduchý vs. příliš složitý model.
- Cross-validace, grafická kontrola a srovnání.



Klíčové funkce
cNORM: Příprava dat

getGroups() – Rozdělí věk do skupin a každému případu přiřadí průměrný věk jeho skupiny; equidistant volí stejně široké nebo přibližně stejně početné skupiny.

rankBySlidingWindow() – Vypočítá předběžné normy podle respondentů v posuvném věkovém okně.

Další funkce pro nachystání opakovaně použitých dat (není nutné, typicky interně).

- rankByGroup() – Vypočítá předběžné percentily samostatně uvnitř skupin.
- computePowers() – Vytvoří mocniny normového skóru a věku a jejich interakce pro polynomiální regresi.
- prepareData() – Lze použít pro předchstání opakovaně použitých dat..

computeWeights() – Pomoc s vážením respondentů.

Klíčové funkce
Odhad a výběr modelu

cnorm() – Připraví data, vytvoří polynomy a odhadne model v jednom kroku.

- bestModel() – Pro případ předem připravených prediktorů.

printSubset() – Přehled modelů s různým počtem regresních členů a ukazatele shody.

plotSubset() – Graficky porovná ukazatele shody a složitost kandidátních modelů.

regressionFunction() – Parametry modelu a koeficienty.

cnorm.cv() – Cross-validace.

plotPercentileSeries() – Série percentilových grafů pro modely s různým počtem regresních členů.

compare() – Graficky porovná percentilové křivky dvou normovacích modelů; při souběžném načtení psych používat cNORM::compare().

Klíčové funkce
Grafické posouzení modelu

plotPercentiles() – Srovná empirické a modelové percentily napříč věkem.

plotNormCurves() – To samé pro standardní skóry.

plotRaw() – Porovná pozorované a modelované hrubé skóry.

plotNorm() – Porovná předběžné a modelové normové skóry.

plotDensity() – Zobrazí křivky rozdělení pro zvolené věky.

plot()/plotCnorm() – Další grafy, viz parametry.

Klíčové funkce
Konzistence modelu

checkConsistency() – Kontrola vertikální monotonicity.

plotDerivative() - Graf první derivaci normativního skóru; pomáhá odhalit porušení vertikální monotonicity a problematické oblasti.

- **derivationTable()** – Vrátí hodnoty první derivace při zvoleném věku v tabulce.

rangeCheck() – Upozorní na extrapolaci mimo věkové rozpětí nebo rozsah předběžných normových skórů použitých při odhadu.

getNormScoreSE() – Vyčíslí odchylku modelových od předběžných normových skórů: type = 2 vrací RMSE, type = 1 variantu SE podle dokumentace.

Klíčové funkce
Export, predikce, normativní tabulky

predictNorm() – Převede hrubý skór a věk na normy inverzí Taylorova polynomu.

predictRaw() – Převede standardní skór a věk na odpovídající hrubý skór.

getNormCurve() – Vrátí hruboskórovou křivku napříč věkem při jednom fixním normovém skóru.

normTable() - U Taylorova modelu přiřadí zvolené řadě normových skórů odpovídající hrubé skóry pro jeden nebo více věků.

rawTable() - U Taylorova modelu přiřadí řadě hrubých skórů normové skóry a percentily; při zadání reliability přidá intervaly pravých skórů.

- Tohle si spíše chcete nachystat sami! Pro tyhle účely má normTable() lepší formát.

Klíčové funkce
Další funkce (parametrické modely, GUI)

Parametrické rodiny modelů:

- **cnorm.shash()** – Parametrický model Sinh-Arcsinh pro spojité skóry; s věkem se mohou měnit poloha, měřítko, šikmost a váha konců.
- **cnorm.betabinomial()** – Beta-binomický model počtu správných odpovědí při známém maximálním skóru.
- **cnorm.cmp()** – Conwayův-Maxwellův-Poissonův model pro celočíselné počty, například počet vyřešených úloh v časovém limitu.
- autoselect.shash(), autoselect.betabinomial(), autoselect.cmp() – Výběr stupně věkových polynomů parametrického modelu podle BIC.
- predictMoments() – Vrátí parametry modelů.

cNORM.GUI() – Spustí grafické rozhraní pro klasické normování s Taylorovými polynomy.

cNORM.GUI2() - Spustí grafické rozhraní pro parametrické modelování.

Děkuji za pozornost!

Hynek Cígler

Katedra psychologie
Institut pro psychologický výzkum
Fakulta sociálních studií, Masarykova univerzita

MUNI FSS Institut pro psychologický výzkum

pdb 2026

Kontakty:

- E-mail: cigler@fss.muni.cz
- ORCID: http://orcid.org/0000-0001-9959-6227
- GitHub: https://github.com/hynekcigler
- OSF: https://osf.io/t6ufg/
- X: https://x.com/HynekCigler

- **Materiály k tomuto workshopu: https://github.com/hynekcigler/cnorm_workshop**