MUNI FSS Institut pro psychologický výzkum

pdb 2026

Workshop: Tvorba kontinuálních norem při vývoji psychodiagnostických metod

Hynek Cígler
Institut pro psychologický výzkum, FSS, Masarykova univerzita

Konference **Psychologická diagnostika Brno 2026** | 22. říjen


10
Joštova
218
Brno-město
VYMÝVÁNÍ MOZKŮ
pondělí - pátek: 8 - 16 hod.
(Individuální zákroky po dohodě s rektorem)
FAKULTA SOCIÁLNÍCH
STUDIÍ


MASARYKOVA UNIVERZITA
NAŠE ŠKOLA SE PYŠNÍ
PRŮMĚRNÝM STUDENTSKÝM
IQ: 63,15 %
FAKULTA SOCIÁLNÍCH
STUDIÍ

Harmonogram

Orientační harmonogram:

- Úvod do norem obecně, výběrová chyba a dopad na měření.
- Formalizace norem. Normy jako funkce, horizontální a vertikální normativní funkce.
- Nenormálně rozložené skóry, normalizace distribuce.
- Potřeba a principy horizontálního a vertikálního vyhlazení.
- Běžné postupy pro kontinuální normování.
- Teorie cNORM přístupu.
- Praktická ilustrace: společně.
- Praktická ilustrace: individuálně.

Veškeré materiály ke stažení: https://github.com/hynekcigler/cnorm_workshop

Normy obecně

V psychologii nemáme až na výjimky dostatečně identifikované a interpretovatelné jednotky.

- Chybí koordinační funkce a kalibrace měřítka.
- Dokonce i W-skóre je závislé na průměrné diskriminační účinnosti položek a měřítko se liší napříč testy.
  - S jednou výjimkou... viz moje přednáška o M-skóru zde na PDB!

Namísto přímého normování skórů proto normujeme jejich interpretaci.

- Kriteriální (clinical cut-offs, LCA, expektační tabulky, CDM...) – je kategorizovaný přímo atribut (typy), nebo jen jeho interpretace (kritické hodnoty kontinuálního skóru)?
- **Normativní interpretace** (norm-referenced tests) – kvantitativní vyjádření kontinuálního rysu.

Druhy odvozených skórů pro kontinuální atributy:

- Percentilové skóry (percentily, percentilové pořadí, decily, steny a staniny...).
- Standardní skóry (lineárně-transformované vs. normalizované...).
- Vývojové skóry (věkový ekvivalent...).
- Další (např. index relativní výkonnosti, RPI).

Reprezentativita norem

Referenční populace, na kterou zobecňujeme.

- Lokální, místní, národní, mezinárodní...

Reprezentativita vůči referenční populaci.

- Sampling design; kvótní, stratifikované, příležitostné výběry...

Otázka vážení (case weigtening).

Téma norem a reprezentativity je v psychometrice podreprezentované a **mimo hlavní zájem**.

- Sociologie? Ekonomie?
- A vlastně i celé téma norem často částečně chybí v typických učebnicích psychometriky (Furr, 2018).

Pro účely tohoto workshopu předpokládáme, že máme reprezentativní vzorek respondentů vůči cílové populaci, a to (pro zjednodušení) bez potřeby vážení.

Nehomogenní referenční populace

Někdy nechceme vztahovat všechny potenciální respondenty k té samé populaci.

- V těchto případech existuje **významný prediktor výkonu**, který chceme zohlednit.
- Nemodelujeme jen průměrný výkon, ale i variabilitu – potenciálně **heteroskedasticita**.

Typicky demografické proměnné.

- Ale nikoli nutně, může jít i o výkon v jiném testu: rozdílové, diskrepanční, ipsativní skóry...
- Často kombinace: např. diskrepanční skór pro konkrétní věkovou skupinu mužů.

Kategorický prediktor.

- Separátní normy pro různé skupiny (pohlaví, klinické populace...).
- Regresní predikce výkonu na základě demografických charakteristik.

Spojitý prediktor: typicky věkově-specifické normy → možnost kontinuálního normování.

- Spojitá nemusí být přímo naše proměnná, ale jen underlying latentní konstrukt.

Výběrová chyba

Každé normy jsou zatížené klasickou výběrovou chybou.
Lineárně-transformovaný skór:

Standardní chyba průměru:

$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}$$

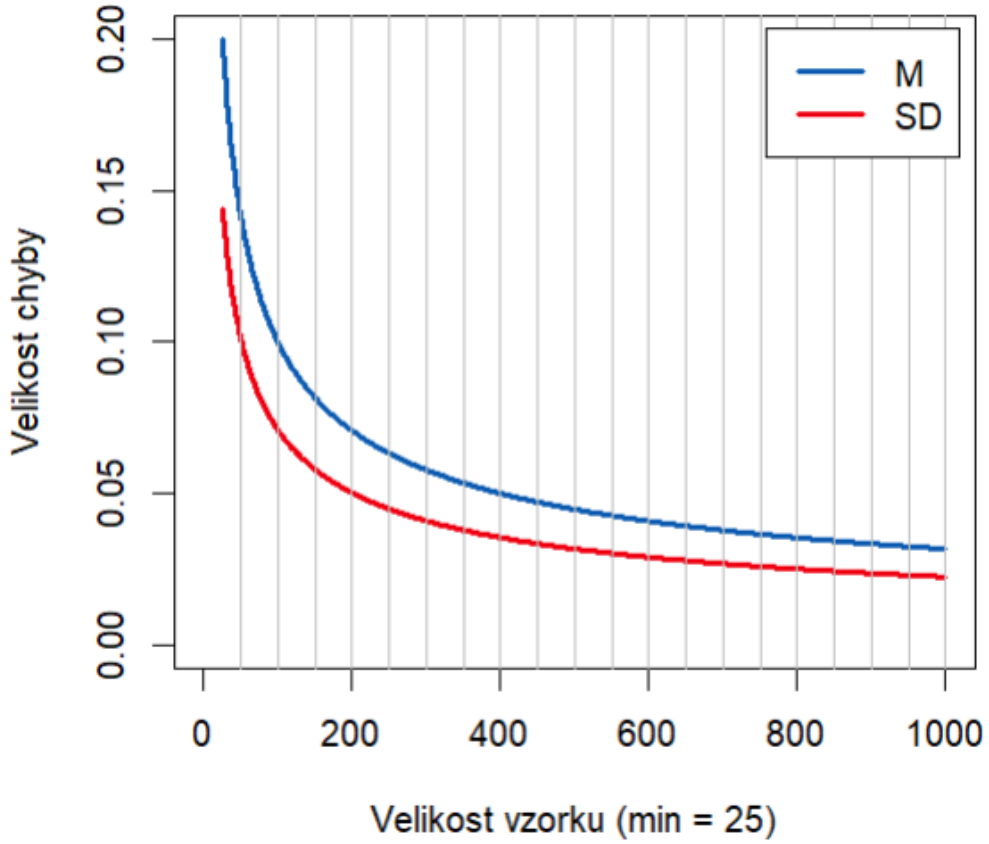
- s – výběrová SD (s $n-1$ ve jmenovateli)
- n – velikost vzorku
- Bez distribučních předpokladů (centrální limitní teorém).

Standardní chyba směrodatné odchylky:

$$\widehat{SE}(s) = \frac{s}{\sqrt{2(n-1)}}$$

- Za předpokladu normálního rozložení.

V případě percentilů: raději simulace!!!



Výběrová chyba: Dopad na normy

Výběrová chyba lineárně-transformovaného skóru:

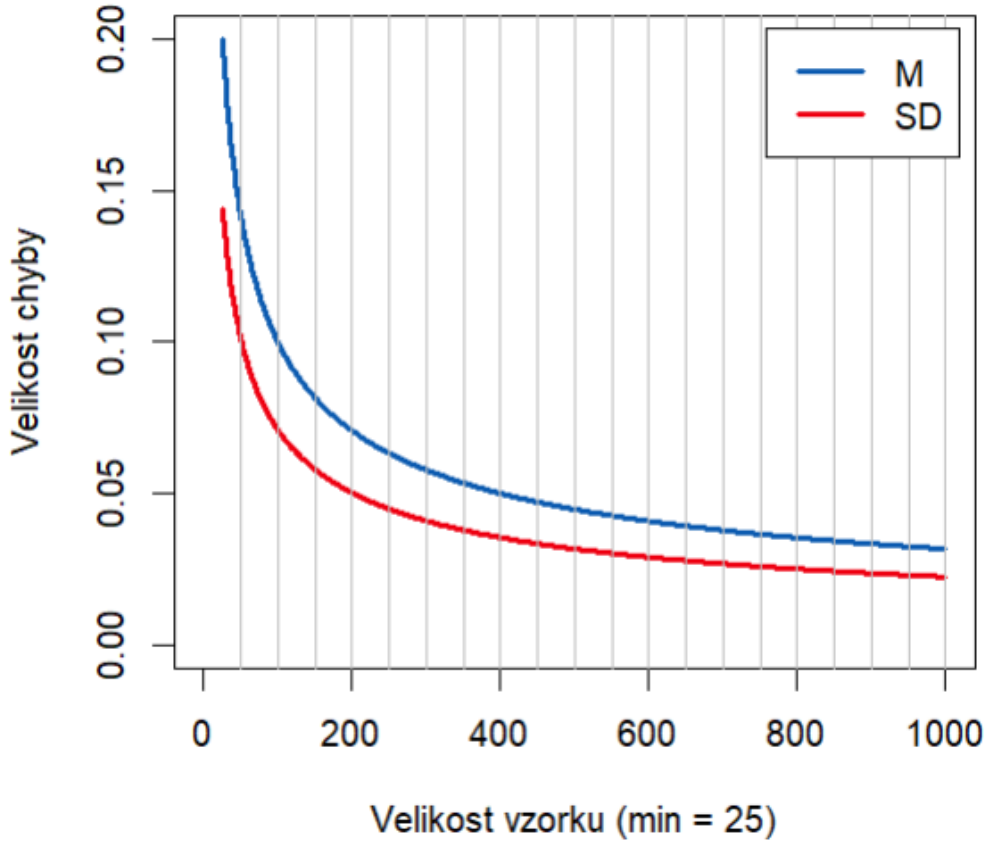
$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}, \qquad \widehat{SE}(s) = \frac{s}{\sqrt{2(n-1)}}$$

Agregovaná chyba konkrétního kvantilu q:

$$\widehat{SE}(q) = \sqrt{\widehat{SE}(\bar{x})^2 + q^2\widehat{SE}(s)^2} = s\sqrt{\frac{1}{n} + \frac{q^2}{2(n-1)}}$$

Roste v extrémech! Pro $s = 1$:

- $\widehat{SE}_{(q=0,n=50)} = .14; \widehat{SE}_{(q=0,n=250)} = .06$
- $\widehat{SE}_{(q=1,n=50)} = .17; \widehat{SE}_{(q=1,n=250)} = .08$
- $\widehat{SE}_{(q=2,n=50)} = .25; \widehat{SE}_{(q=2,n=250)} = .11$
- $\widehat{SE}_{(q=3,n=50)} = .33; \widehat{SE}_{(q=3,n=250)} = .15$



Výběrová chyba: Dopad na normy

Výběrová chyba lineárně-transformovaného skóru:

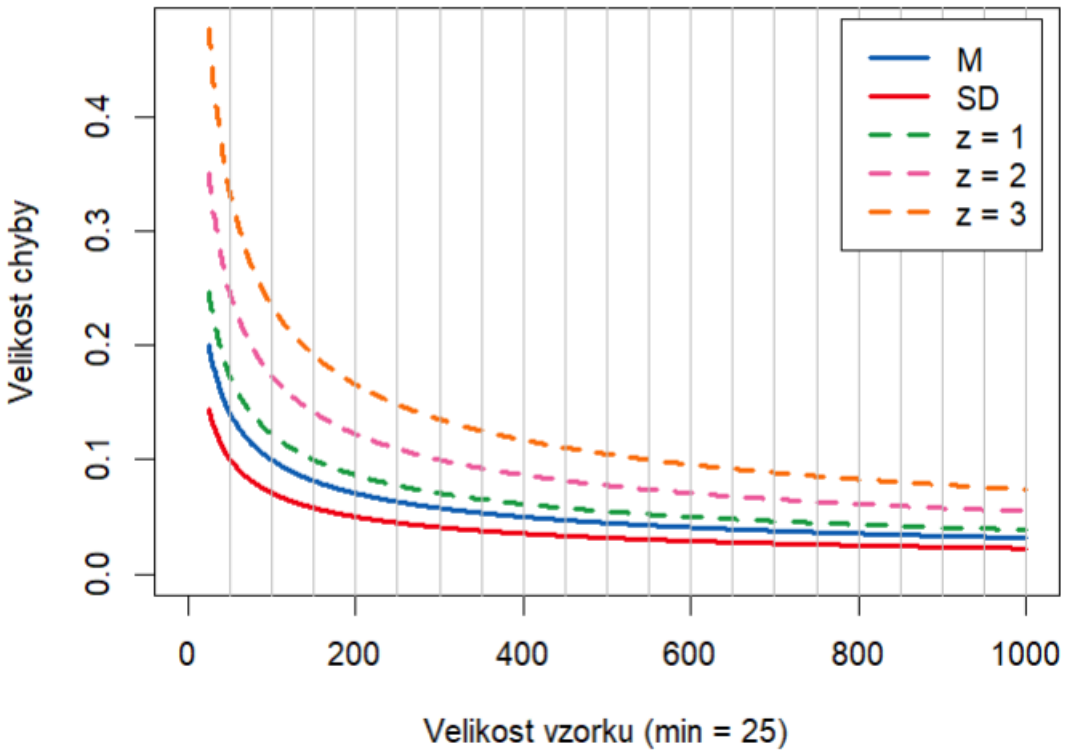
$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}, \qquad \widehat{SE}(s) = \frac{s}{\sqrt{2(n-1)}}$$

Agregovaná chyba konkrétního kvantilu q:

$$\widehat{SE}(q) = \sqrt{\widehat{SE}(\bar{x})^2 + q^2\widehat{SE}(s)^2} = s\sqrt{\frac{1}{n} + \frac{q^2}{2(n-1)}}$$

Roste v extrémech! Pro $s = 1$:

- $\widehat{SE}_{(q=0,n=50)} = .14; \widehat{SE}_{(q=0,n=250)} = .06$
- $\widehat{SE}_{(q=1,n=50)} = .17; \widehat{SE}_{(q=1,n=250)} = .08$
- $\widehat{SE}_{(q=2,n=50)} = .25; \widehat{SE}_{(q=2,n=250)} = .11$
- $\widehat{SE}_{(q=3,n=50)} = .33; \widehat{SE}_{(q=3,n=250)} = .15$



Výběrová chyba: Dopad na interpretaci skóru

Výběrová chyba přidává další šum k běžné chybě měření (SE).

Postup 1: **Teorie zobecnitelnosti** – typicky(!) jen chyba průměru.

- 1fasetový model $p \times I$ + chyba průměru osob ve vzorku, $\bar{p}$:

$$\sigma_\delta^2 = \frac{\sigma_{pi}^2}{N_i} + \left(\frac{\sigma_p^2}{N_p} + \frac{\sigma_{pi}^2}{N_p N_i} \right)$$

- N_i – počet položek v testu
- N_p – počet osob v normativní studii

Postup 2: **Agregace standardní chyby měření SE a standardní chyby odhadu kvantilu $SE(q)$**:

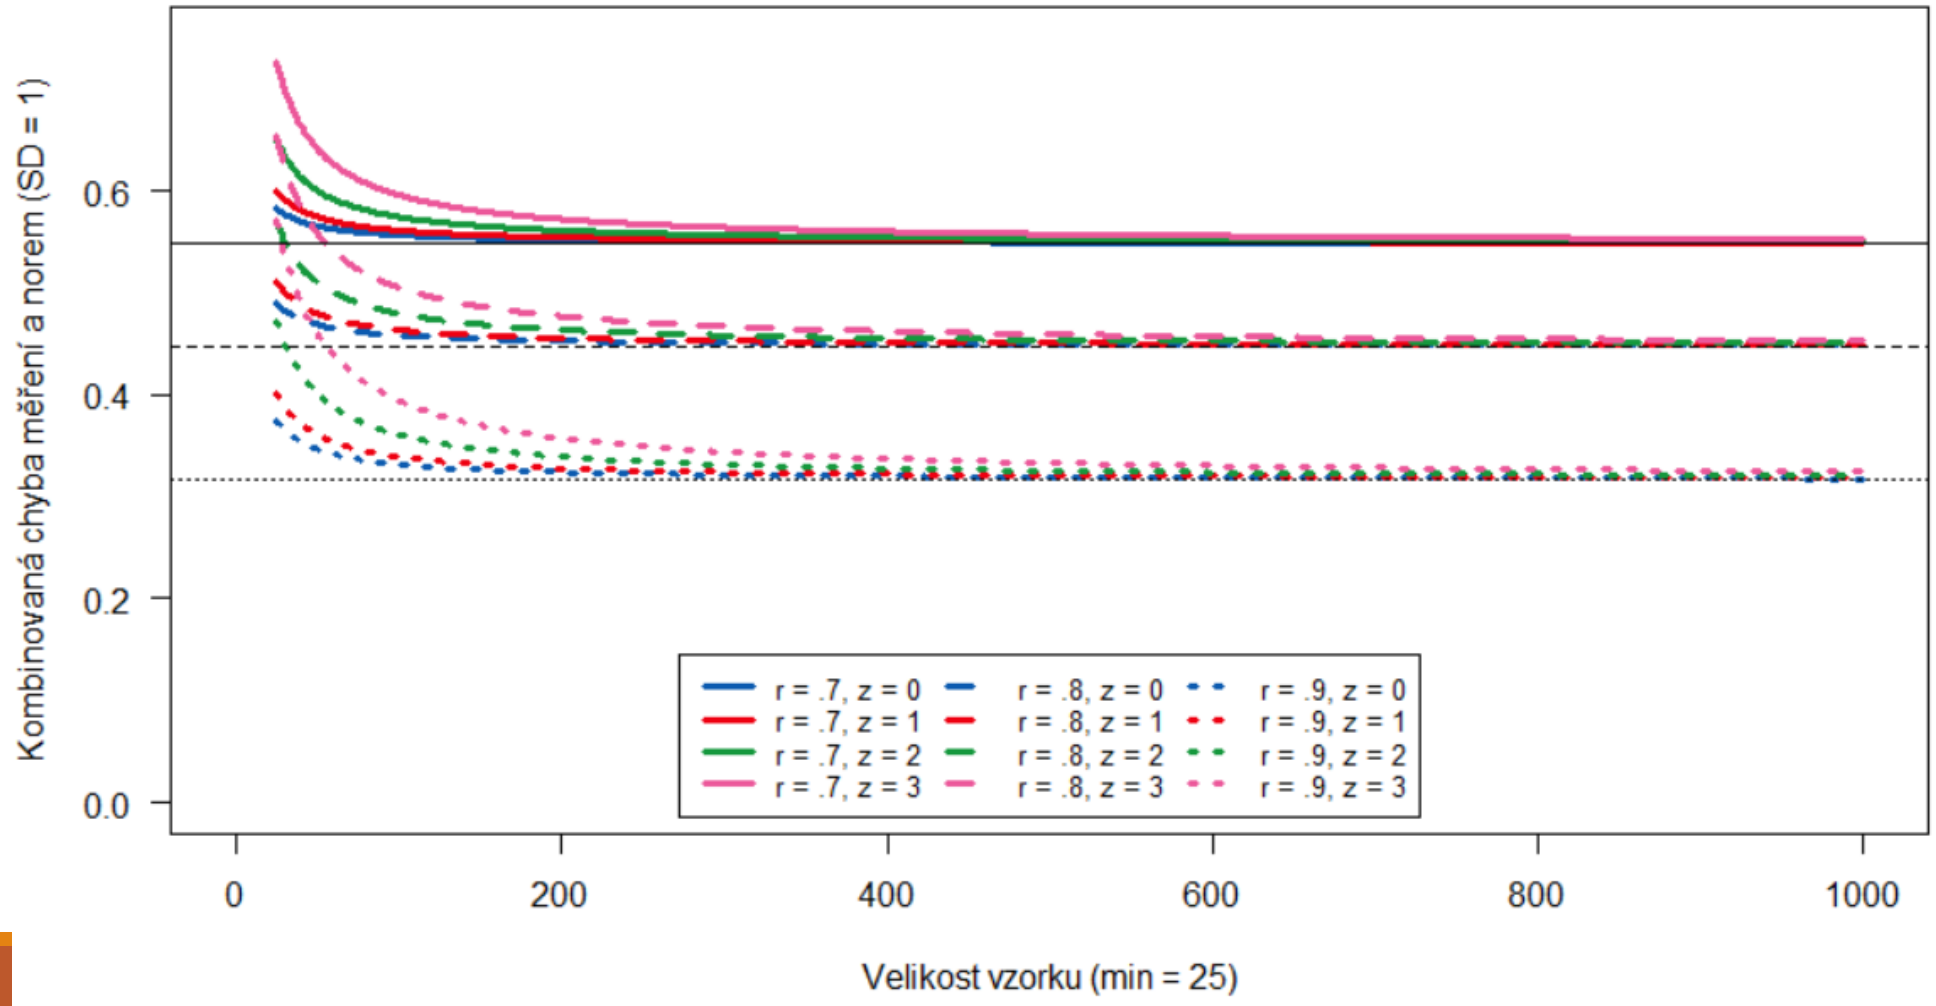
$$SE_{comb}(q) = \sqrt{SE_x^2 + SE(q)^2} = s\sqrt{(1 - r_{xx'}) + \frac{1}{n} + \frac{q^2}{2(n-1)}}$$

Vliv výběrové chyby norem:

- Po agregaci s chybou měření nečekaně slabý!
- Klesá s rostoucím N a roste s extremitou skóru.
- Jen málo (a nehomogenně) je závislý na reliabilitě.

s = 1	SE	n= 50	n= 250	n= 1000
r=.7, x=0	.55	.57 (.14)	.55	.55
r=.7, x=1	.55	.57	.55	.55
r=.7, x=2	.55	.60	.56	.55
r=.7, x=3	.55	.64	.57	.55
r=.9, x=0	.32	.35	.32	.32
r=.9, x=1	.32	.36	.33	.32
r=.9, x=2	.32	.40	.33	.32
r=.9, x=3	.32	.46	.35	.32

Výběrová chyba: Dopad na interpretaci skóru



Normalizace skórů a percentily

Interpretace standardních skórů vyžaduje normální rozložení.

- Neplatí samozřejmě pro percentily.

Potřeba normalizace nenormálně rozložených skórů, nebo použití percentilu.

Percentily ale svádí k interpretačním chybám – **APA doporučuje T-skóry**.

- Škála není lineární, jednotky představují rozdílnou míru výkonu.
- Svádí k nadhodnocení rozdílů u průměru, podhodnocení rozdílů v extrémech.
- Nelze s nimi dále analyticky pracovat (sčítat, použít v analýzách).
- Součet percentilů není percentil.
- Snadná záměna s procentuální správnosti.
- Na první pohled intuitivní, korektní interpretace ale náročná.

Normalizace skórů: parametricky

Parametrická transformace (logaritmizování, odmocnění).

- Jen v opodstatněných případech (např. reakční časy).

Normalizace podle průměru nebo mediánu (např. WJ-IV$_{US}$).

- Výpočet specifické SD pro nad/podprůměrné: $s_- = \sqrt{\frac{2\sum_{x_i<\bar{x}}(x_i-\bar{x})^2}{2n_- - 1}}$, $s_+ = \sqrt{\frac{2\sum_{x_i>\bar{x}}(x_i-\bar{x})^2}{2n_+ - 1}}$.
- Výpočet standardního skóre s použitým příslušné směrodatné odchylky.

Výhodou parametrických postupů je, že lze **stejným způsobem transformovat i chyba měření**.

- V případě parametrické transformace nicméně dochází k změně její distribuce!
  - Lze zanedbat nebo použít výslednou distribuci – např. pro logaritmované skóry log-normální rozdělení.
- V případě normalizace podle průměru/mediánu pozor na CI zahrnující průměr!
  - Je potřeba „seskládat“ dohromady.

Normalizace skórů: neparametricky

McCallova plošná transformace.

- Skór je převeden na percentil a ten je následně převeden na příslušný kvantil cílové jednotky.
- Zatíženo velmi obtížně parametrizovatelnou chybou odhadu percentilu.

Jiné nelineární transformace.

- Např. Taylorovy polynomy, obsah tohoto workshopu, nebo GAMLSS.
- Chybu normalizace je zpravidla nutné simulovat.

V těchto případech **není snadné odhadnout výslednou chybu měření po transformaci**.
Správný postup konstrukce CI:

- 1. Odhad intervalu spolehlivosti pro hrubé skóre.
- 2. Teprve tento interval transformovat společně s bodovým odhadem.

Dokud je ale transformace monotónní a bijektivní, neovlivňuje reliabilitu!

Normy jako funkce

V případě běžných norem závislých na věku jsou normy funkcí věku (a) a hrubého skóru (x):

$$S_{norm} = f(x, a)$$

Tato funkce může mít různou podobu a lze uvažovat i specifické funkce jedné z proměnných:

- **Pro konkrétní věk vertikální funkce:**
  - a_k: $f_{a_k}(x) \coloneqq f(x, a_k)$ – např. $7 \leq a_k < 8$leté děti.
- **Pro konkrétní HS horizontální funkce:**
  - x_l: $f_{x_l}(a) \coloneqq f(x_l, a)$ – např. 10 bodů; inverzní funkce pak např. IQ 70 nebo 90. percentil.

Na tyto dílčí funkce typicky klademe nějaké zjevné požadavky:

- Ideálně minimalizace výběrové chyby.
- „Plynulost“, resp. regularita ($f \in C^1$)
- Spojitost, po celém definičním oboru (či jeho části) monotónicita (minimálně vertikálně).
  - Např. všechny $f_{x_l}(a)$ by v dětství měly být monotónní klesající (u starších dětí stejný hrubý skór → nižší standardní skór).
  - Žádné $f_{x_l}(a)$ by se neměly křížit; důsledek monotónních $f_{a_k}(x)$, tedy vyšší hrubý skór → vyšší standardní skór.

Potřeba horizontálního vyhlazení

Jakákoli transformace na odvozený skór **v každé věkové kohortě odděleně** (separátní konstrukce vertikálních funkcí $f_{a_k}(x)$) vyžaduje diskretizaci jinak spojitého věku. Důsledek:

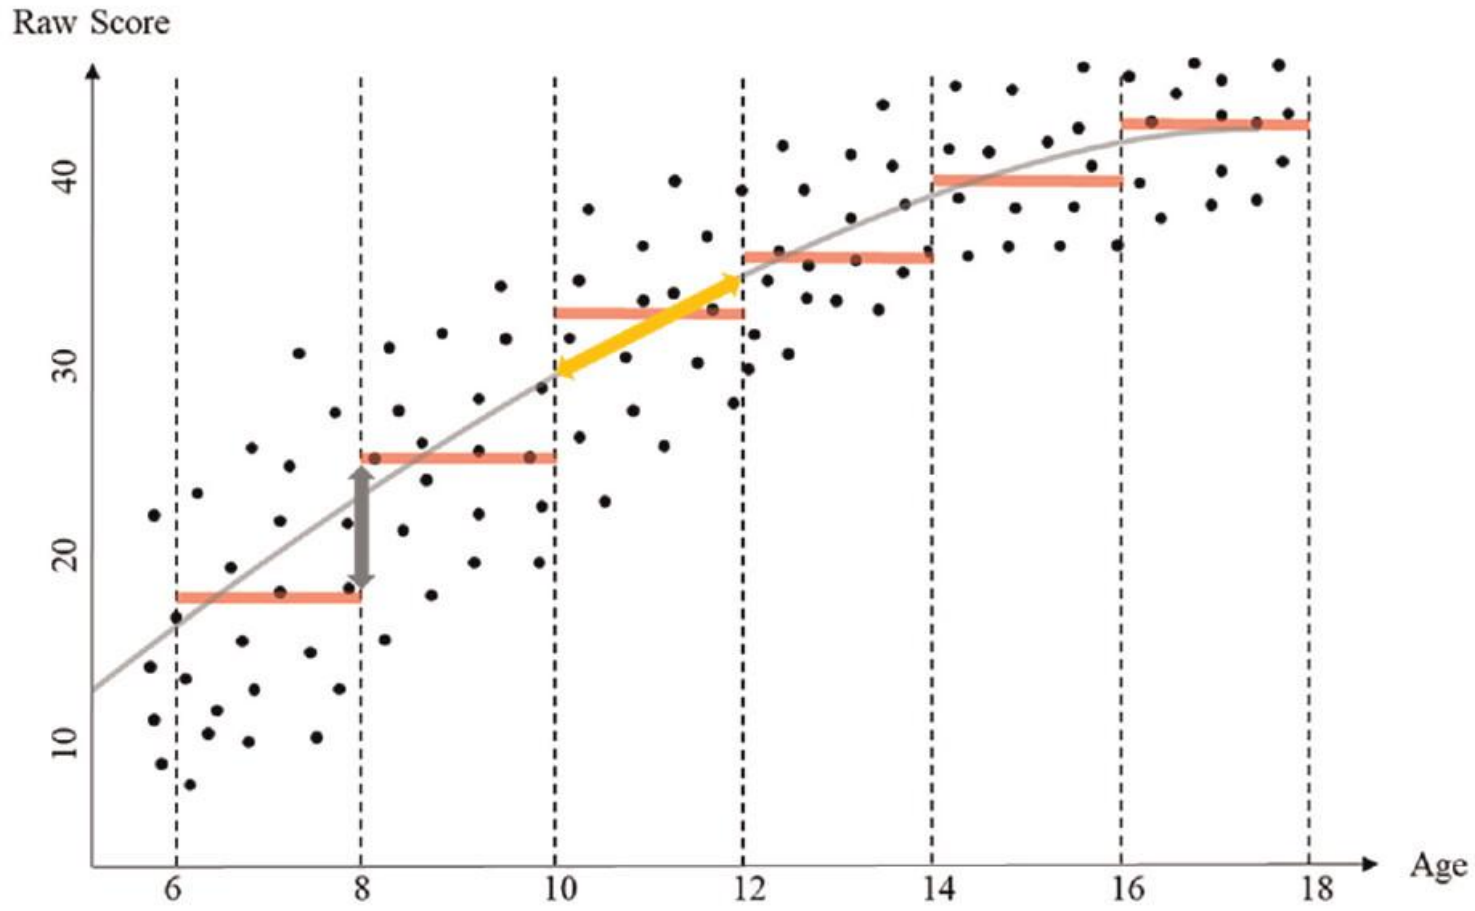
Horizontální funkce $f_{x_l}(a)$ není spojitá: konstantní uvnitř kohort, na hranicích schodovitá.

- To zvyšuje normativní chybu vůči původní kontinuální proměnné věku, a to zejm. v oblasti hranic kohort a rychle se měnících rysů.
- V důsledku výběrové chyby parametrů vertikálních funkcí $f_{a_k}(x)$ a částečně i výběrové chyby průměrného věku $\bar{a}_k$ dané kohorty není funkce regulární – není plynulá, hladká, spojitá.
- Není monotónní tam, kde bychom to čekali – nutnost ručních úprav.

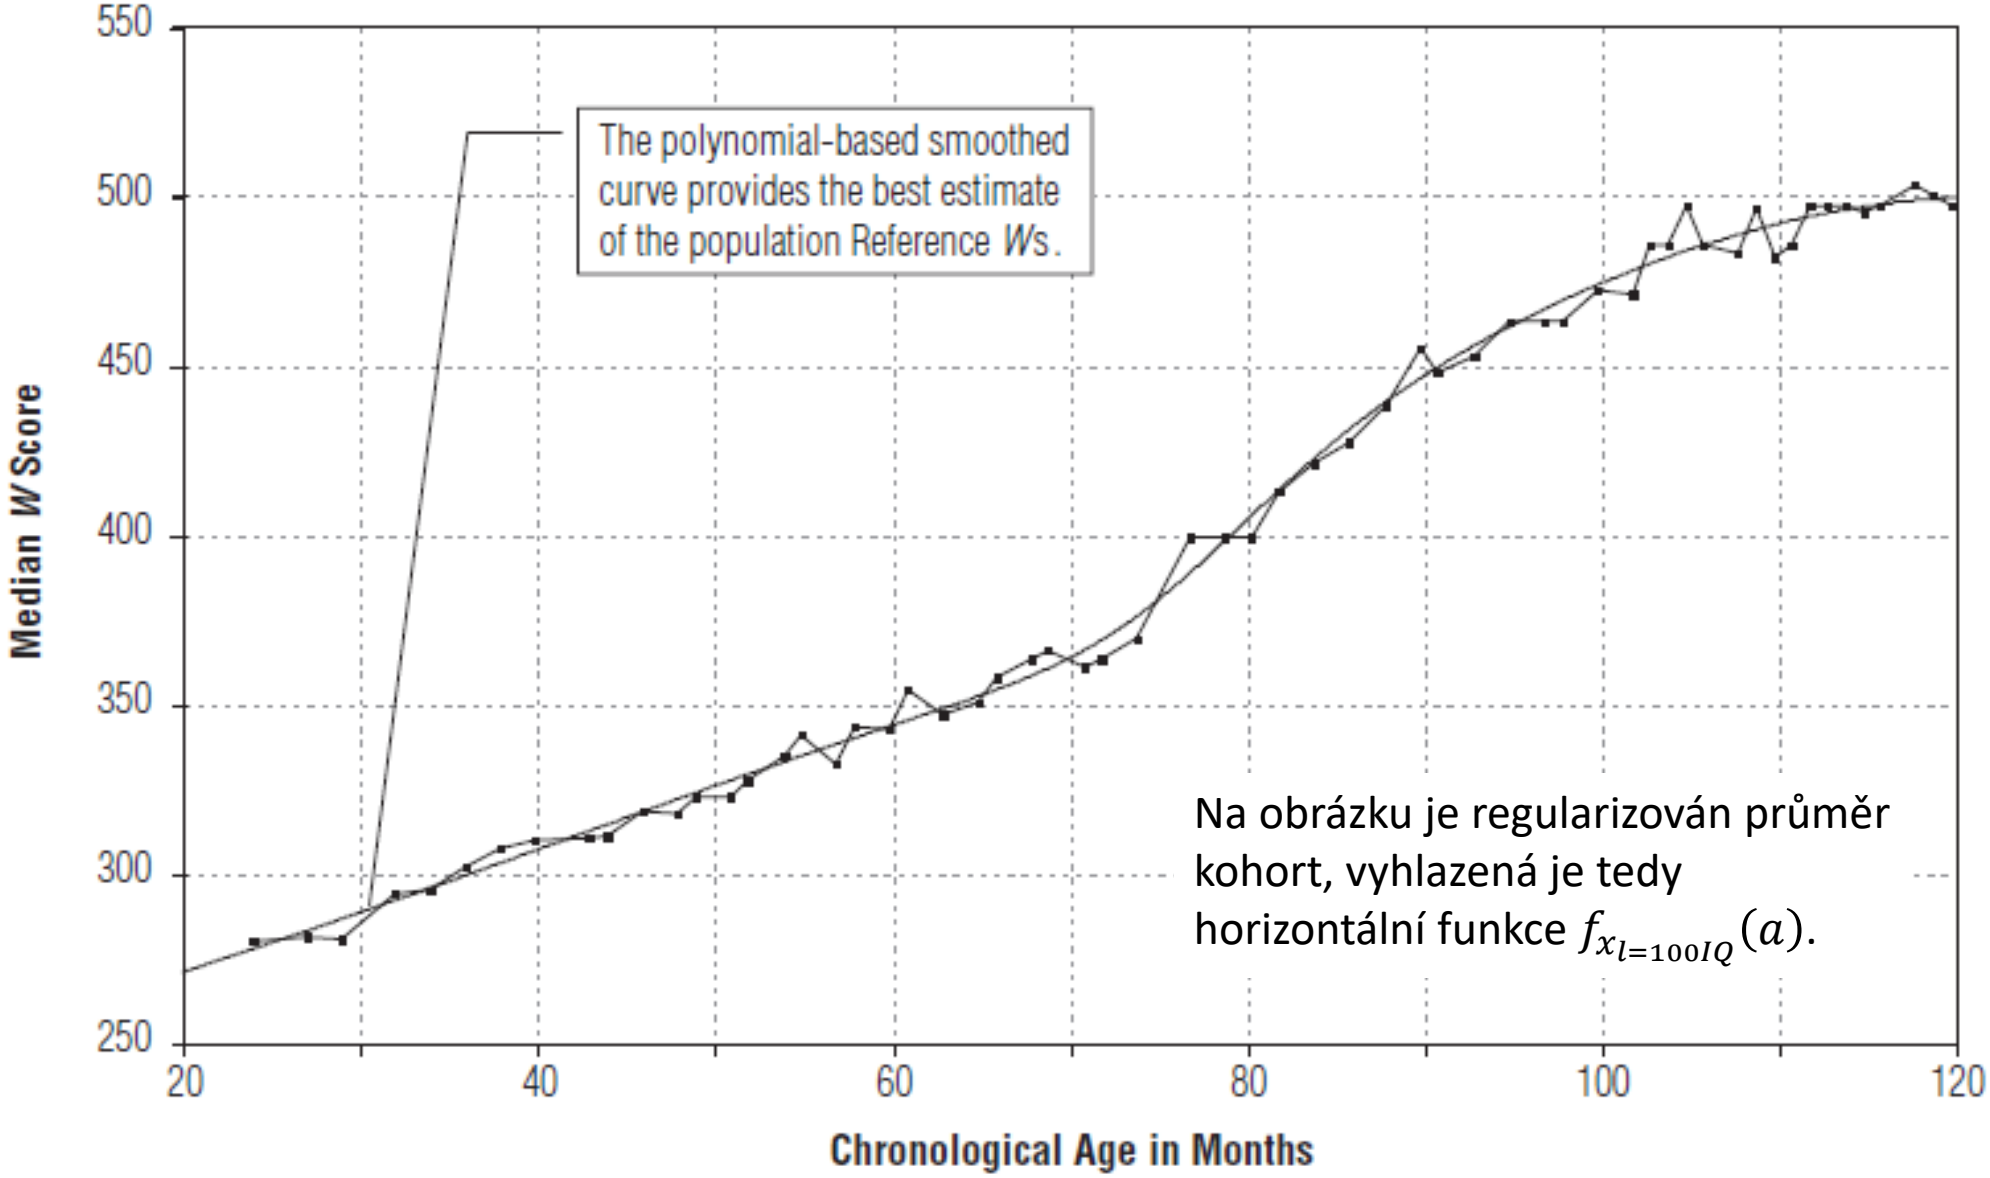
Řešení: Horizontální vyhlazení (regularizace horizontálních funkcí $f_{x_l}(a)$).

- Stejných skórů napříč věkem, resp. parametrů vertikální funkce napříč kohortami.

Potřeba horizontálního vyhlazení



https://doi.org/10.1177/10731911241260545

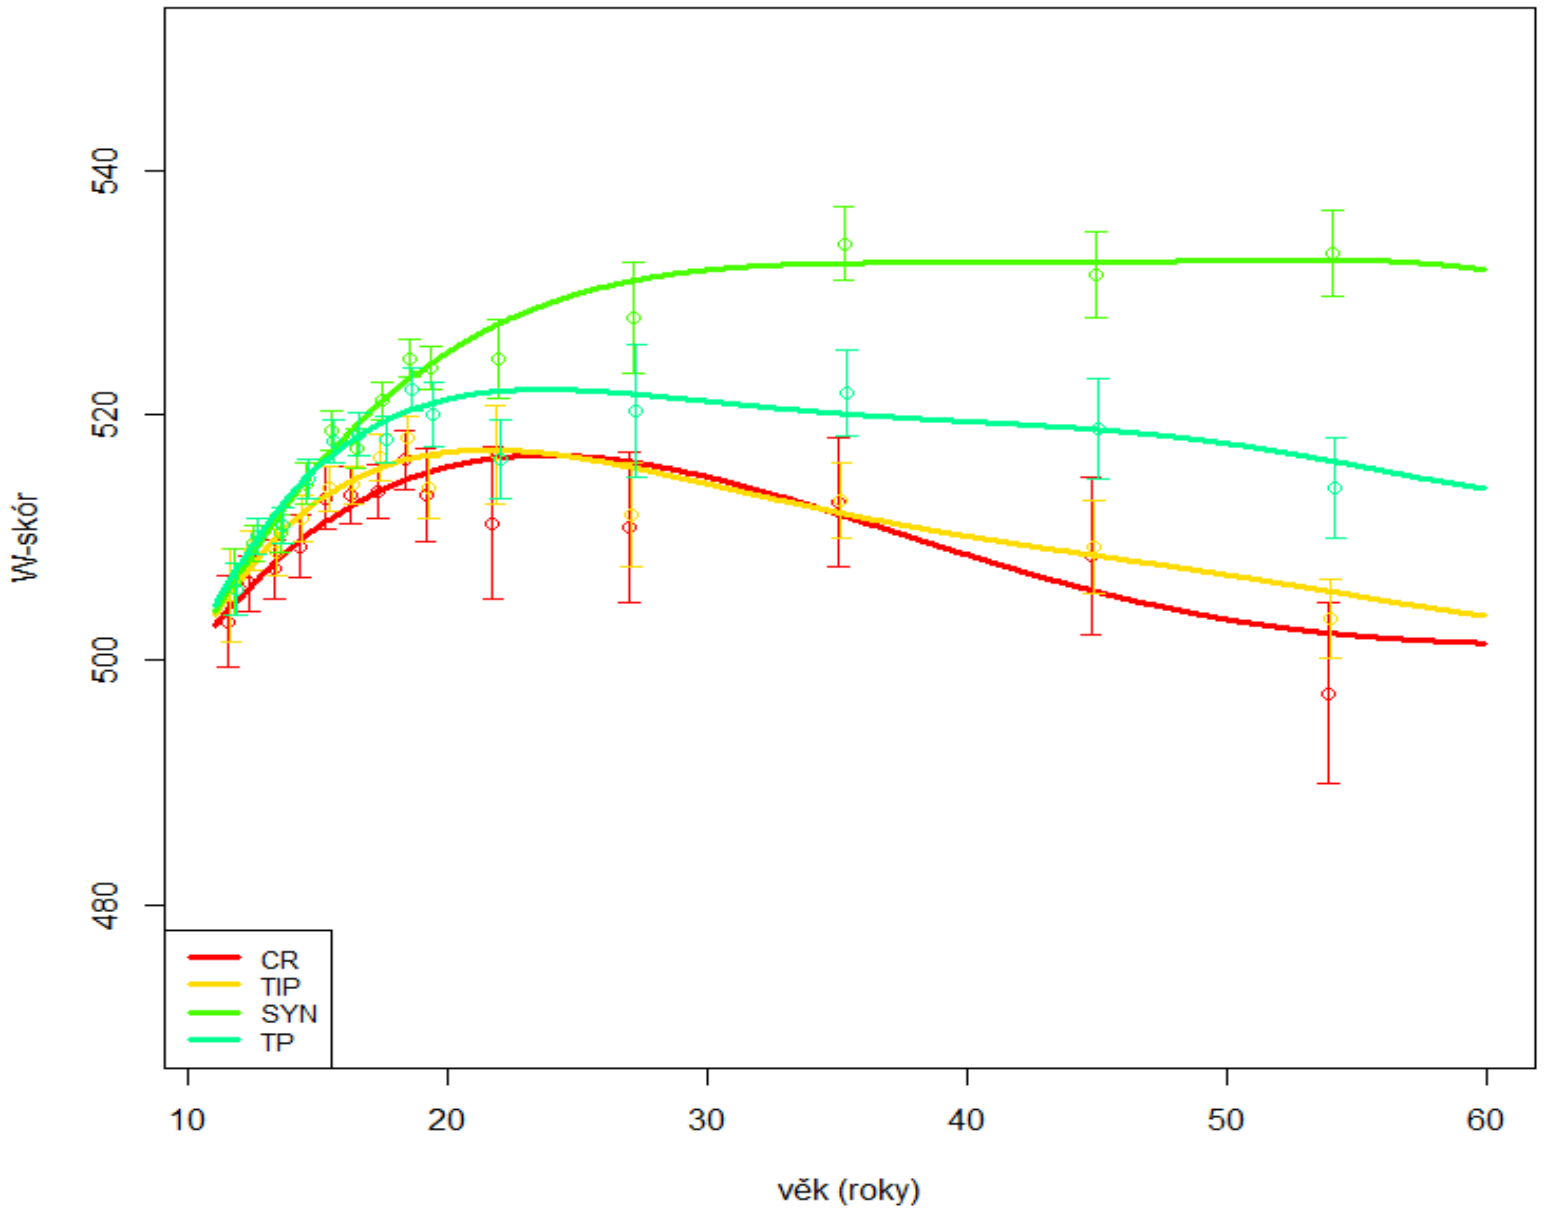


Na obrázku je regularizován průměr kohort, vyhlazená je tedy horizontální funkce $f_{x_{l=100IQ}}(a)$.

Note. A similar process is completed with the standard deviations (*SD*s) for Letter-Word Identification.

Technický manuál WJ-IV

Cígler et al. (2017)
Krátký inteligenční test



Potřeba vertikálního vyhlazení

Standardní skóry nelze interpretovat, pokud jsou výrazně nenormálně rozložené.

Standardní postup plošné transformace má ale znatelnou **výběrovou chybu, zejm. v extrémech**.

- Distribuce malých vzorků je navíc méně centrální (Studentovo t-rozložení) – systematická chyba.
- Což dále umocňuje potíže potíže s neregularitou horizontální funkce $f_{x_l}(a)$.
- A dále také zvyšuje výběrovou chybu norem.

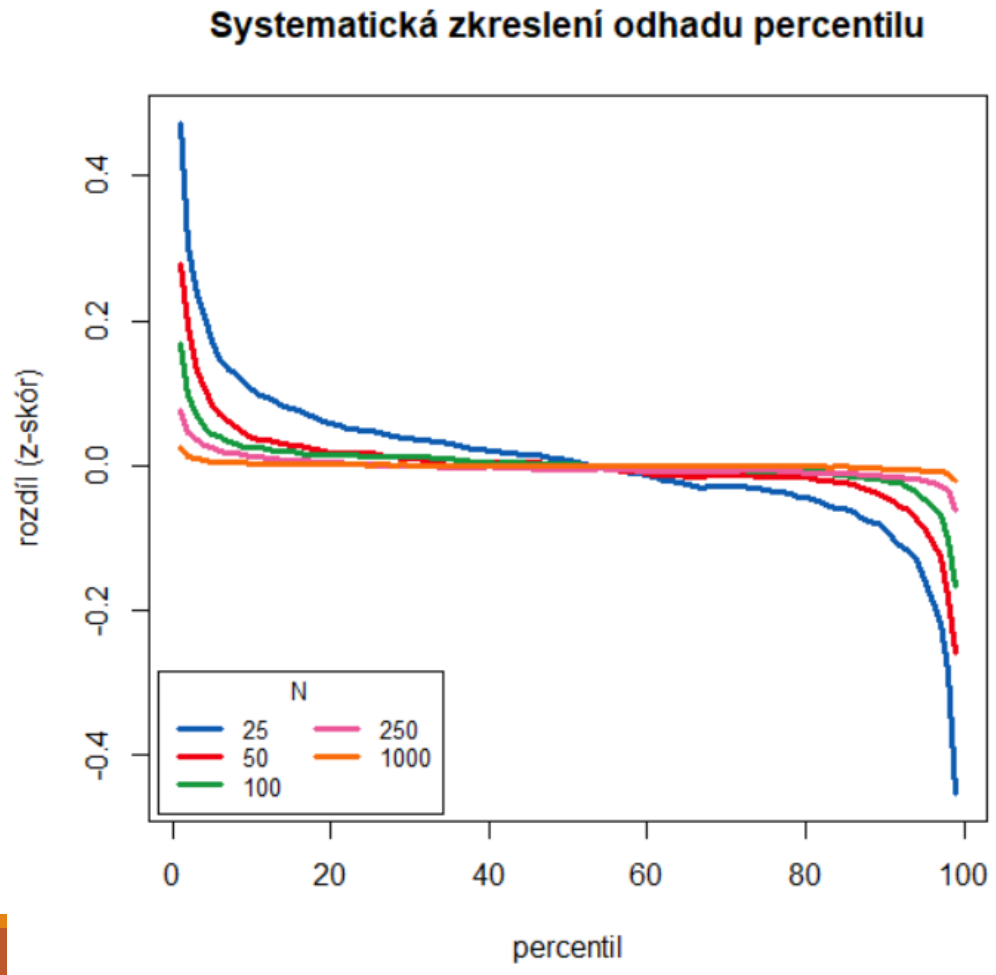
Kromě toho je kumulativní distribuční funkce nutná pro tvorbu percentilu „**schodovitá**“.

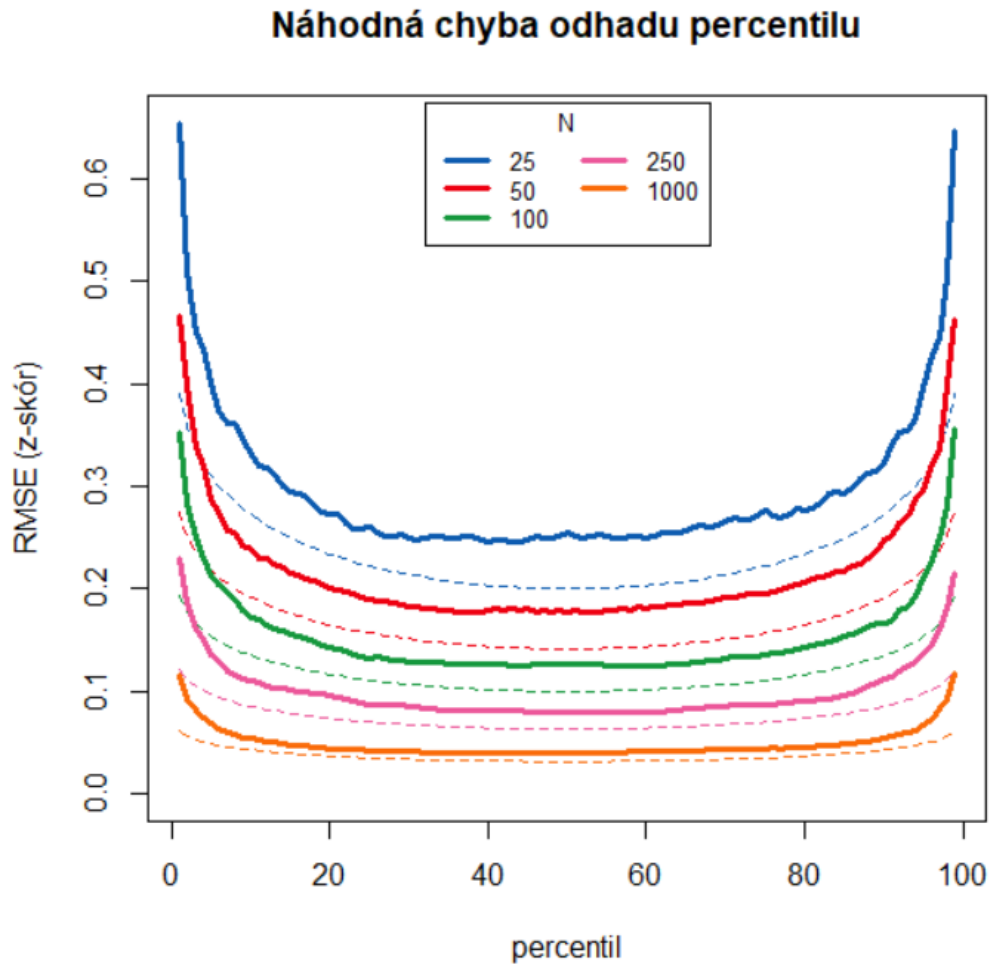
Řešením je vyhlazení vertikální funkce $f_{a_k}(x)$ – tedy její regularizace.

- V případě lineárně-transformovaných standardních skórů je $f_{a_k}(x)$ přirozeně regularizovaná!
- Jsou-li tedy hrubé skóry normálně rozložené, je jednoznačně výhodné použít lineární transformaci.
  - V případě cNORM jen polynom prvního řádu pro lokaci, k = 1.
- Další výhoda (nevýhoda?) lineární transformace: aproximace mimo pozorované skóry vzorku.

Chyba odhadu percentilu

(Za předpokladu normálního rozložení, 1000 náhodných vzorků)





Chyba odhadu obecně

Chyby popsané výše jsou ideální, spodní hranicí výběrové chyby.

- Nad simulovanými nebo dobře fungujícími daty.

Reálná normativní data nenáhodných výběrů jsou zašuměná, schodovitá, malá...

- Na nenáhodných vzorcích vznikají systematické výběrové chyby.

Počítejte s tím, že normativní chyba je vždy mnohem větší.

Ideální, velké a náhodně vybrané vzorky je ale těžké zajistit.

- Zajistit co největší variabilitu příležitostného výběru.
- Hodně různých sběračů, heterogenní nábor respondentů... chyby se „vyruší“?

Samostatné vertikální vyhlazení

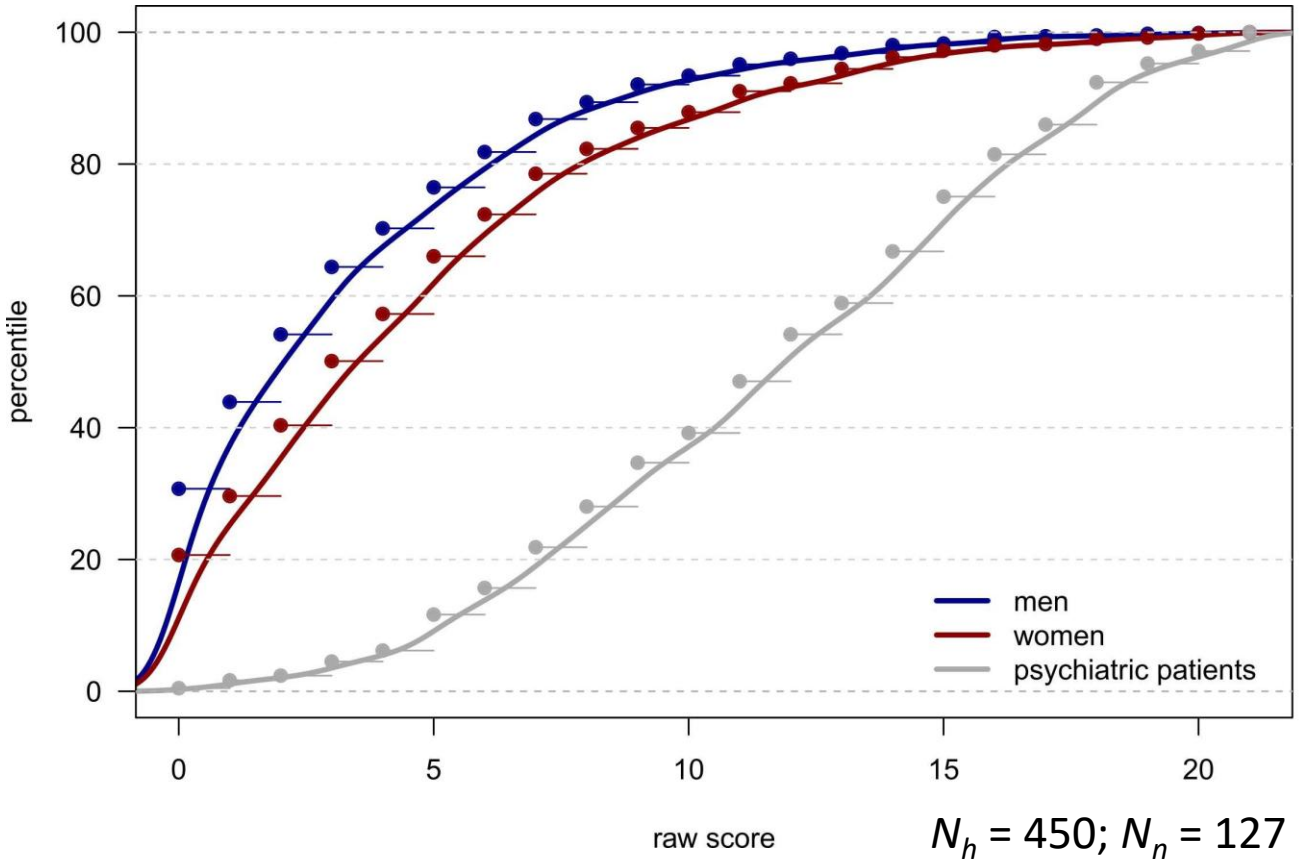
Pokud je jen jediná kohorta nebo neexistuje spojitý prediktor a je realizovaná plošná transformace, samostatné vertikální vyhlazení je jednoduché.

Optimální postup: Kernelovská kumulativní distribuční funkce (KCD).

- Proloží „schodovité“ percentily regularizovanou distribuční funkcí.

Neodstraní plochost malého vzorku!

Nejjednodušší implementace: `ks::kcde`.



N_h = 450; N_n = 127

GAD-7 (Cígler et al., 2026): https://doi.org/10.1016/j.janxdis.2026.103149

Přehled postupů kontinuálního normování

Přehled postupů

Urban, J., Scherrer, V., Strobel, A., & Preckel, F. (2025). Continuous Norming Approaches: A Systematic Review and Real Data Example. *Assessment, 32*(5), 654-674. https://doi.org/10.1177/10731911241260545

- Vyhlazení skupinových charakteristik (**inferential norming**) – průměr, směrodatná odchylka.
- **Regresní normy** (**simplified parametric norming**).
- Distribuční regrese, typicky GAMLSS (**parametric norming**).
  - Případně též Box-Cox LMS transformace.
- **Semiparametrické normy pomocí Taylorových polynomů (cNORM).**

Další postupy:

- Kvantilová regrese – přímé regresní modelování hranic kvantilů v závislosti na věku (funkcí $f_{x_l}(a)$).
- Kontinuální normy **založené na IRT** s věkově-podmíněnou distribucí latentního rysu.
  - Tohle je můj nový favorit!

Přehled postupů

Jsou cNORM opravdu nejlepším postupem?

- Jsou rozhodně lepší než diskrétní normy (Urban et al., 2025; Heister et al., 2024).
- Jsou rozhodně lepší než zjednodušené regresní normy.
- Naopak IRT-based postupy mohou být lepší (Heister et al., 2024) a logicky to dává smysl.
- Parametrické GAMLSS normy v simulačních studiích vycházejí nepřekvapivě nepatrně lépe.

Regresní normy

Používané zejména v klinické psychologii a neuropsychologii.

Regresní model: závislá proměnná je HS, prediktory věk či další demografie (např. vzdělání).

- Vztah může být i kvadratický či složitější.

1. Odhad očekávaného výkonu $\hat{X}_i$ osoby i s danou kombinací charakteristik (zde jen věk a_i):

$$\hat{X}_i = \hat{\beta}_0 + \hat{\beta}_1 a_i$$

2. Standardní skóre je pak odhadnuto s pomocí směrodatné odchylky reziduí s_e:

$$\hat{z}_i = \frac{X_i - \hat{X}_i}{s_e}$$

Extrémně jednoduchý postup, ale silné předpoklady, zejména:

- homoskedasticita, adekvátnost lineárního modelu (lineární, kvadratický... vztah).
- Dodatečně normalita reziduí.
- Neomezený definiční obor (žádné efekty stropu či podlahy).

Regresní normy

Existuje více rozšiřujících variant.

Normalizace před regresí.

- Např. plošná transformace.
- Obsahuje jiné silné předpoklady.

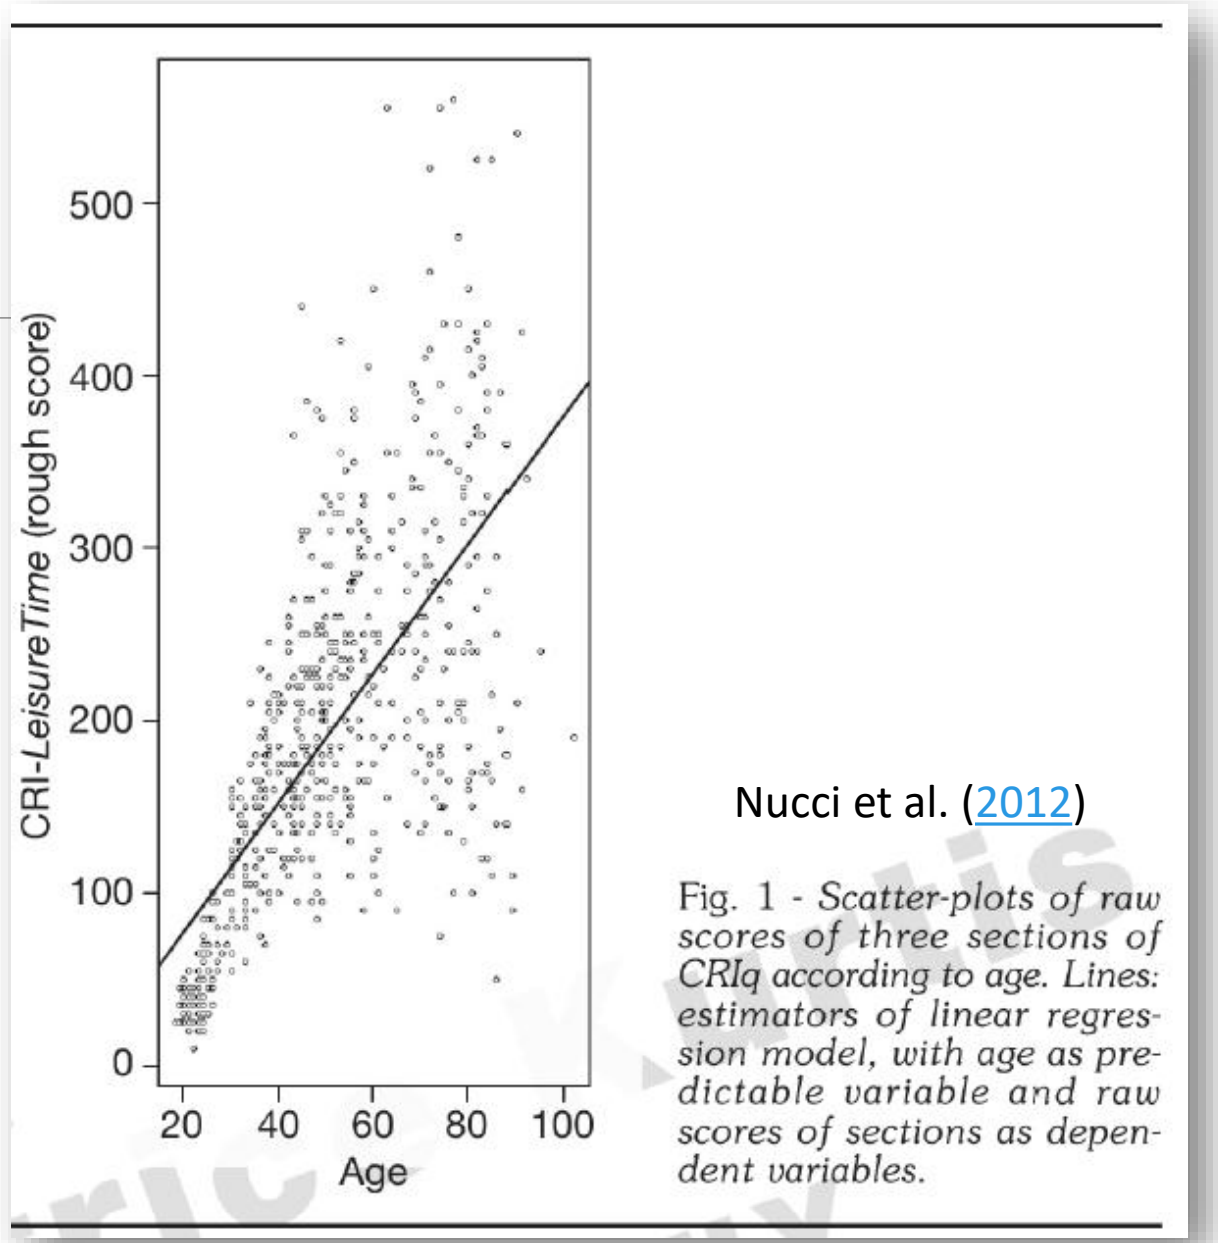
Generalized Additive Models for Location, Scale, and Shape (GAMLSS)

- Rigby & Stasinopoulos (2005)

Robustní regrese.

- Částečně řeší heteroskedasticitu.

Žádná z variant není univerzální a bezpečná!!!



Nucci et al. (2012)

Fig. 1 - *Scatter-plots of raw scores of three sections of CRIq according to age. Lines: estimators of linear regression model, with age as predictable variable and raw scores of sections as dependent variables.*

Inferenční normy
Horizontální vyhlazení parametrů lineární transformace

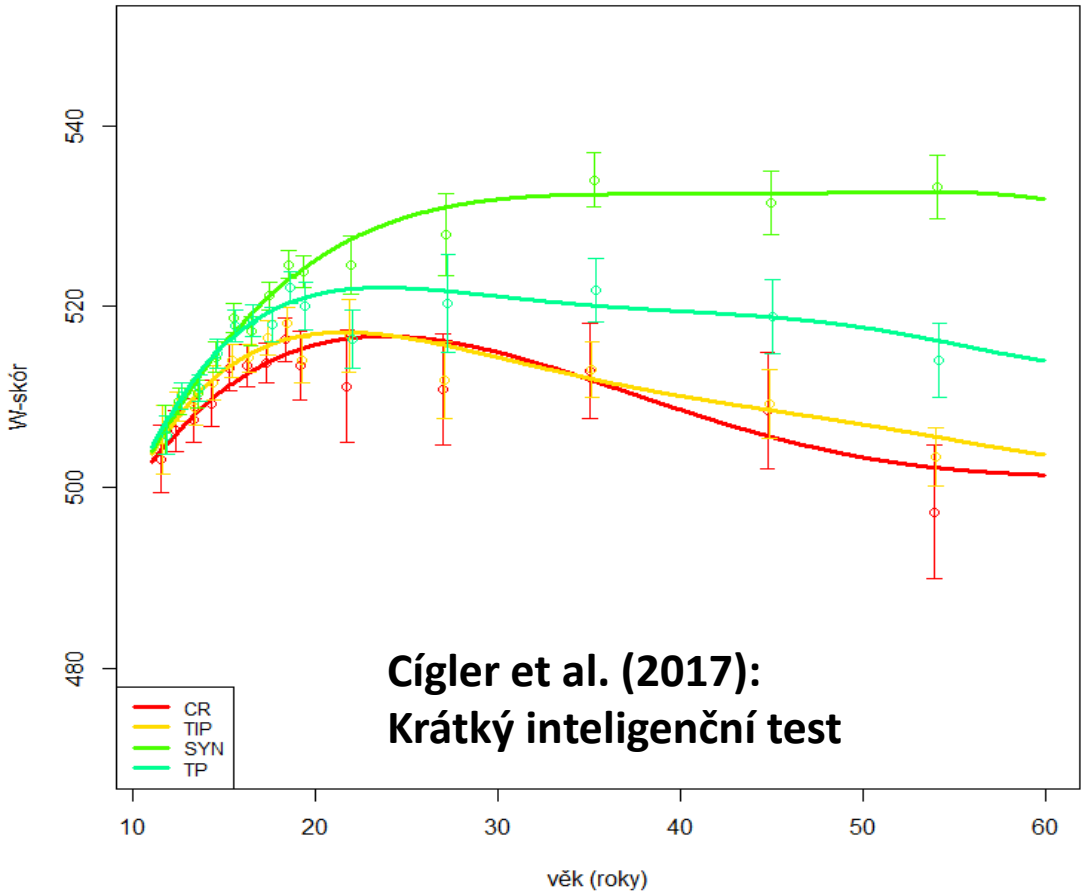
Odhad parametrů pro lineární transformaci pro každou kohortu zvlášť.

- Přinejmenším průměr ($\hat{x}_{a_k}$) a směrodatná odchylka ($\hat{s}_{a_k}$), případně obě směrodatné odchylku po rozdělení dle průměru ($\hat{s}_{-a_k}$, $\hat{s}_{+a_k}$).

Parametry jsou následně proloženy polynomickou regresí, loess, spline apod.

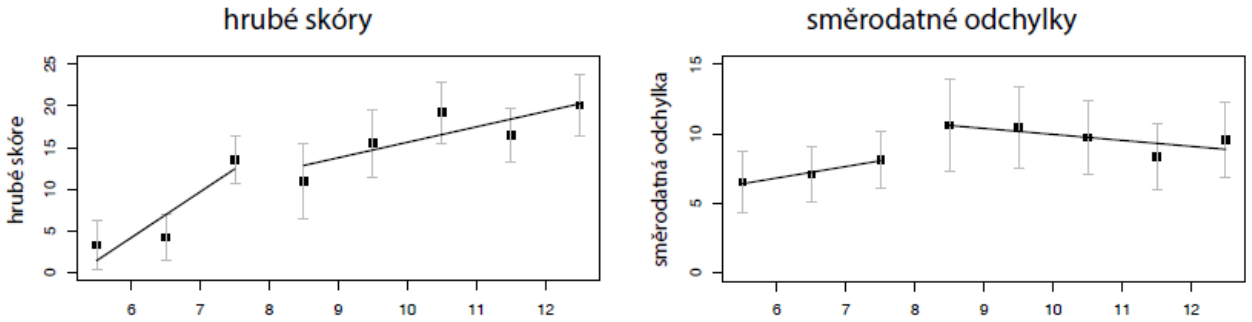
Lineární transformace garantuje vertikálně hladké skóry ($f_{a_k}(x)$).

Vyhlazení parametrů v kombinaci s lineární transformací zajistí horizontální vyhlazení pro všechny přípustné hrubé skóry ($f_{x_l}(a)$).

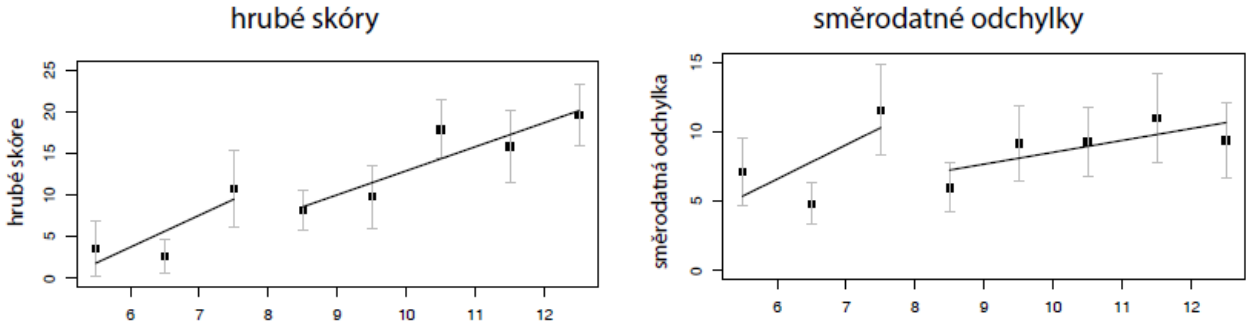


Inferenční normy
Horizontální vyhlazení parametrů lineární transformace

obr. 17: **Vývoj průměrů a směrodatných odchylek hrubého skóre podle věku u dívek – regresní odhad a bodové odhady pro jednotlivé věkové skupiny vč. 95% int. spolehlivosti**



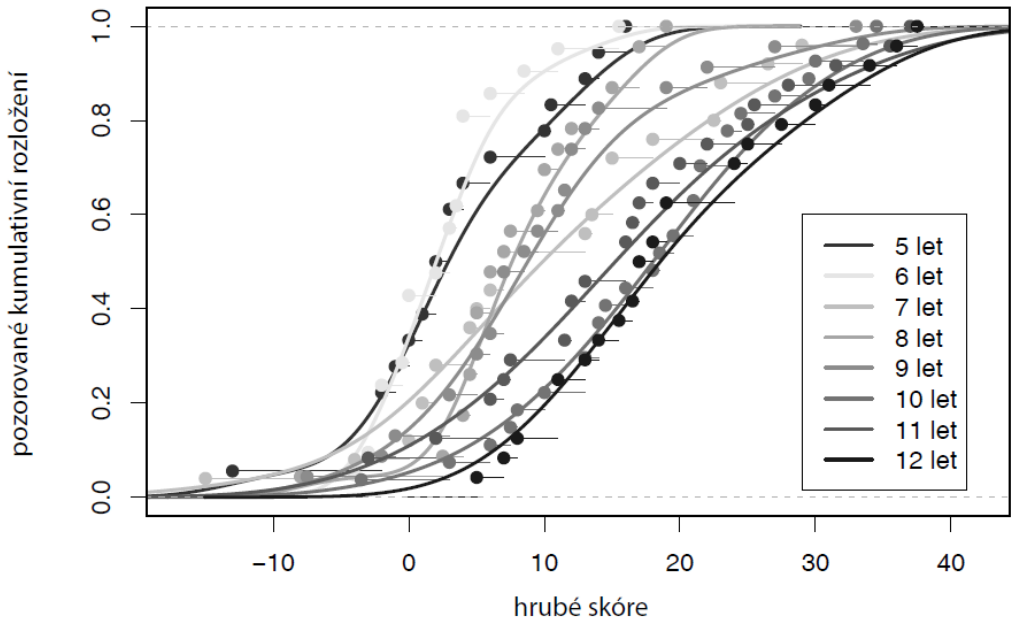
obr. 18: **Vývoj průměrů a směrodatných odchylek hrubého skóre podle věku u chlapců – regresní odhad a bodové odhady pro jednotlivé věkové skupiny vč. 95% int. spolehlivosti**



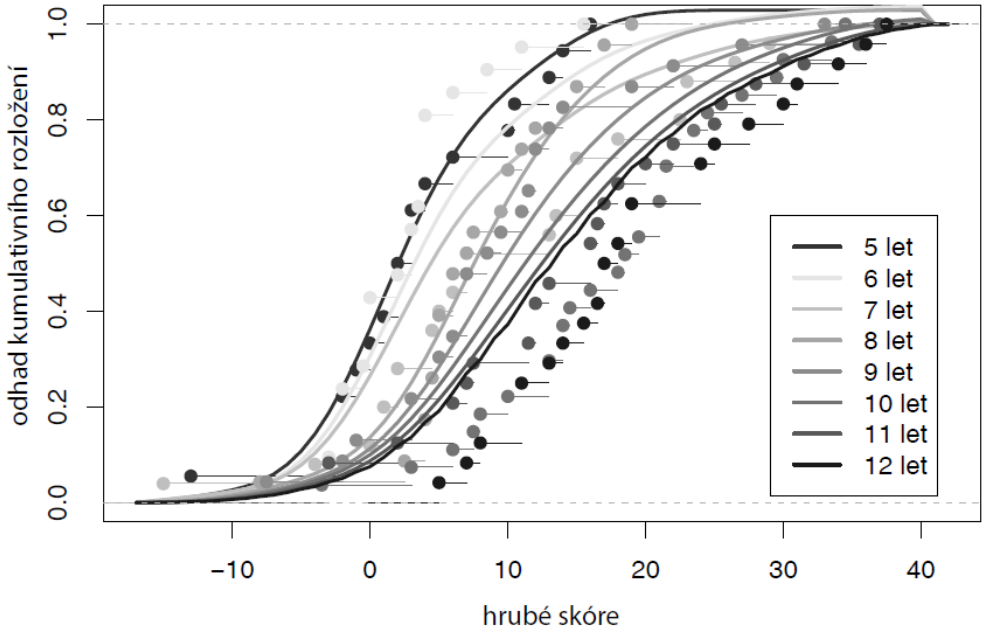
Test vyprávění příběhů (Cígler a Durmeková, 2017)

Alternativní postup: Vyhlazená sdílená multivariační kumulativní pravděpodobnost

obr. 20: **Pozorované kumulativní rozložení hrubého skóre chlapců podle věkových skupin**
(viz též barevná příloha, s. 79)



obr. 22: **„Vyhlazený" odhad kumulativního rozložení pro chlapce napříč věkovými skupinami**
(viz též barevná příloha, s. 80)



Test vyprávění příběhů (Cígler a Durmeková, 2017)
Prostřednictvím knihovny ks jako $P(a,b) = P(A \leq a) \cap P(B \leq b)$. Zpětně lze odhadnout $P(b|a)$ pro konkrétní hrubý skór „b": $P(b|a) = P(a,b)/P(A \leq a)$. Nemyslím, že to fungovalo dobře...

cNORM

Semiparametrické kontinuální normy pomocí Taylorových polynomů

cNORM

Primární autoři balíčku: Lenhard, Lenhard, & Gary (2018)

Semiparametrický přístup, který souběžně realizuje vertikální i horizontální vyhlazení bez distribučních předpokladů.

- Taylorovy polynomy aproximují hodnoty funkce jednodušším polynomem bez distribučních předpokladů.

cNORM balíček nedávno implementoval i vážení respondentů.

Od roku 2024 nabízí cNORM i parametrické modelování s distribučními přepodklady.

- beta-binomický model pro silové testy s hrubým skóre
- CMP (Conway-Maxwell-Poisson Distribution) pro rychlostní testy (počet úloh za čas)
- SHASH (Sinh-Arcsinh Distribution) pro obecné spojité skóry (parametry analogické M, SD, Sk, K).
  - Tohle je typicky podobné GAMLSS.

cNORM: Postup s Taylorovými polynomy

1. Rozdělení vzorku na kohorty, v každé provizorní odhad klasického percentilového skóru (l) a průměrného věku (a).

2. Vytvoření Taylorových polynomů ($a^1, a^2, \dots, a^T$ a $l^1, l^2, \dots, l^K$) a jejich interakcí ($a^1 l^1, a^1 l^2, \dots, a^1 l^k, a^2 l^1, \dots, a^k l^k$); typicky $K \leq T \leq 4$.

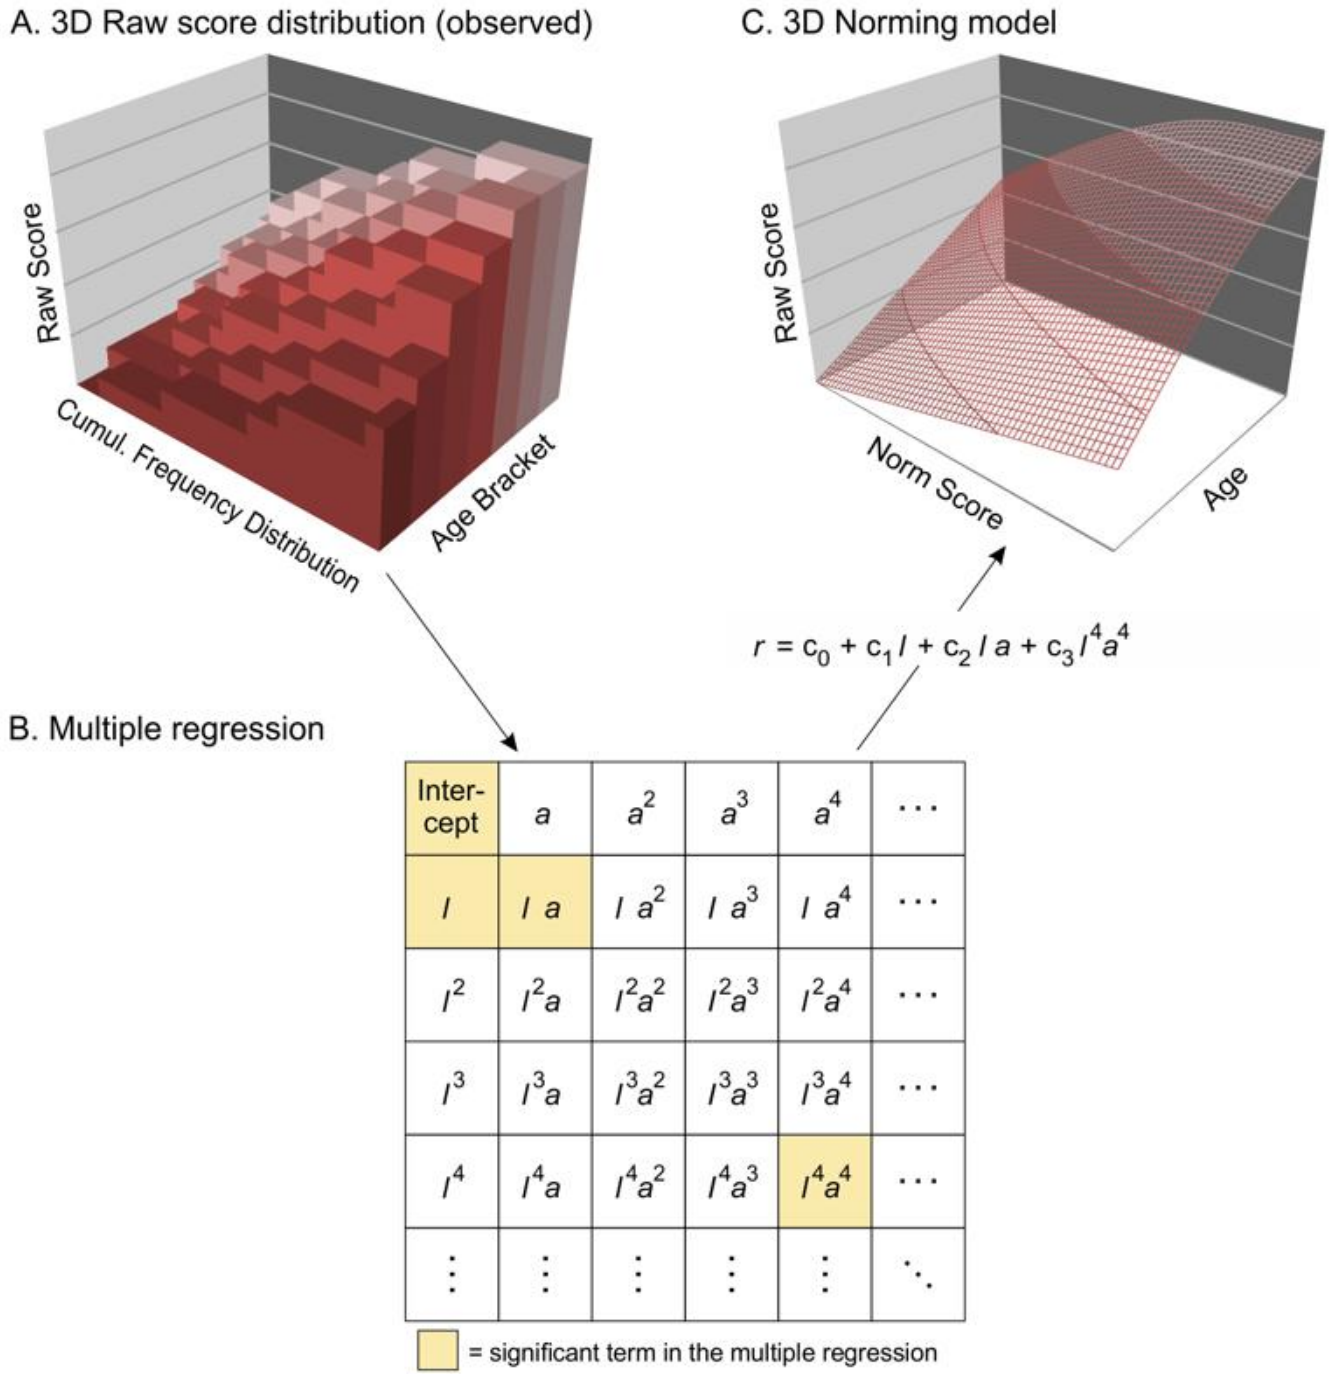
3. Odhad série regresních modelů predikujících hrubý skór r:

$$r \approx \sum_{k=0}^{K} \sum_{t=0}^{T} \beta_{k,t} \cdot l^k \cdot a^t + e$$

- Všimněte si, že je zde opačná logika než u dříve představených funkcí $f(x, a)$, závislou je hrubý skór!
  - Ryze arbitrární volba; vlastně si nejsem zcela jistý, proč přesně.

4. Výběr nejlepšího modelu (cross-validace a další postupy).

5. Model použit pro predikci standardního skóre (l) z věku (a) a pozorovaného hrubého skóre (r).


A. 3D Raw score distribution (observed)
Raw Score
Cumul. Frequency Distribution
Age Bracket
C. 3D Norming model
Raw Score
Norm Score
Age
$r = c_0 + c_1 l + c_2 l a + c_3 l^4 a^4$
B. Multiple regression
Inter-cept
a
a^2
a^3
a^4
l
$l\ a$
$l\ a^2$
$l\ a^3$
$l\ a^4$
l^2
l^2a
l^2a^2
l^2a^3
l^2a^4
l^3
l^3a
l^3a^2
l^3a^3
l^3a^4
l^4
l^4a
l^4a^2
l^4a^3
l^4a^4
= significant term in the multiple regression

cNORM: Postup s Taylorovými polynomy

Významná úspora parametrů.

- Diskrétní lineárně-transformované normy pro respondenty 5–20 let: 2×16 = 32 parametrů!
- cNORM – typicky jen pět až šest (byť silně kolineárních) parametrů.
  - Kolinearita nám nevadí – podstatný je průběh predikce a koeficient determinace, ne hodnota prediktorů.

Značné riziko over-fittingu – nutnost cross-validace!

Velikost vzorku (klinická zkušenost HC):

- mnoho malých skupin – špatné fungování norem v extrémech, lepší okolo průměru
- málo velkých skupin – horší vyhlazení okolo průměru, ale lepší fungování v extrémech

Porušení vertikální monotonicity – nutnost „omezení“ skórů.

- CMP = Conway-Maxwell-Poisson Distribution
- SHASH = Sinh-Arcsinh Distribution

Parametrické možnosti

	Distribution-free (Taylor)	Beta-binomial	CMP	SHASH
Score scale	Continuous or discrete	Integer, $0 \leq y \leq n$	Integer, $y \geq 0$	Continuous, $y \in \mathbb{R}$
Typical tests	General ability and achievement	Power and accuracy tests	Speeded tests, rate tasks	Continuous measures, response times
Upper bound	Post-hoc clipping to $[minRaw, maxRaw]$	Natural bound (n items)	Open-ended, or truncated via `max_score`	None
Distributional shape	Any (empirical)	Binomial with beta mixing	Over-, equi- or under-dispersed	Skewed, light or heavy tails
Main strength	Maximum flexibility	Respects fixed item numbers	Models the dispersion directly	Handles negative and uncentred scores
Function	`cnorm()`	`cnorm.betabinomial()`	`cnorm.cmp()`	`cnorm.shash()`

Závěrem úvodu

Primárně mluvím o cNORM s Taylorovými polynomy.

Ale není to jediný a ani ideální postup – parametrické možnosti mohou fungovat lépe, zejména na malých datech.

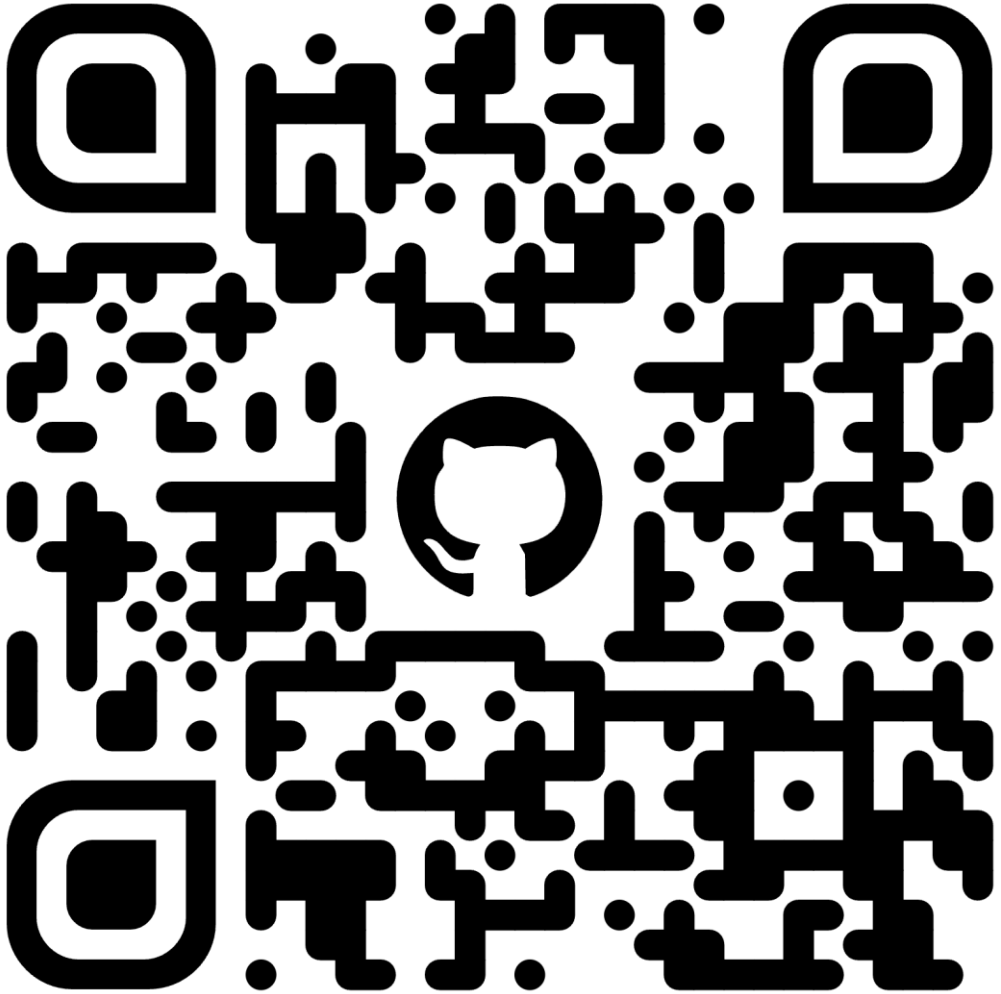
Take-home message:

Jakékoli kontinuální normy (snad vyjma prostých regresních) jsou lepší než diskrétní normy.

Konkrétní design je nutné volit s ohledem na data.

Pojďme si to vyzkoušet!

Veškeré materiály, podklady, skripty a cvičná data jsou k dispozici na GitHubu.



https://github.com/hynekcigler/cnorm_workshop

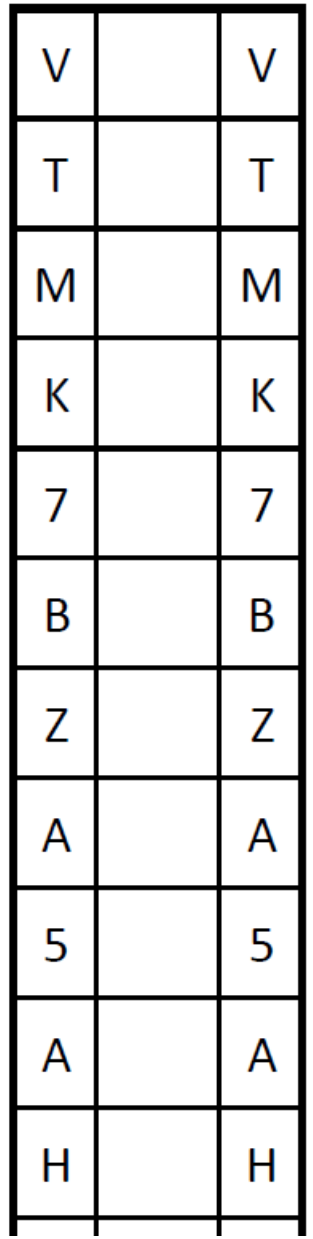
Praktická ukázka

T01: Test Grafomotorického tempa. Prostý přepis tří sloupců znaků.

- Test je parametrizován pomocí log-normálního IRT modelu (viz samostatná přednáška na PDB), hrubým skórem je M-skór – 10leté děti mají M = 0.

Témata:

- Různý počet skupin, funkce rankBySlidingWindow().
- Různý počet parametrů, příliš jednoduchý vs. příliš složitý model.
- Cross-validace, grafická kontrola a srovnání.



Klíčové funkce
cNORM: Příprava dat

getGroups() – Rozdělí věk do skupin a každému případu přiřadí průměrný věk jeho skupiny; equidistant volí stejně široké nebo přibližně stejně početné skupiny.

rankBySlidingWindow() – Vypočítá předběžné normy podle respondentů v posuvném věkovém okně.

Další funkce pro nachystání opakovaně použitých dat (není nutné, typicky interně).

- rankByGroup() – Vypočítá předběžné percentily samostatně uvnitř skupin.
- computePowers() – Vytvoří mocniny normového skóru a věku a jejich interakce pro polynomiální regresi.
- prepareData() – Lze použít pro předchstání opakovaně použitých dat..

computeWeights() – Pomoc s vážením respondentů.

Klíčové funkce
Odhad a výběr modelu

cnorm() – Připraví data, vytvoří polynomy a odhadne model v jednom kroku.

- bestModel() – Pro případ předem připravených prediktorů.

printSubset() – Přehled modelů s různým počtem regresních členů a ukazatele shody.

plotSubset() – Graficky porovná ukazatele shody a složitost kandidátních modelů.

regressionFunction() – Parametry modelu a koeficienty.

cnorm.cv() – Cross-validace.

plotPercentileSeries() – Série percentilových grafů pro modely s různým počtem regresních členů.

compare() – Graficky porovná percentilové křivky dvou normovacích modelů; při souběžném načtení psych používat cNORM::compare().

Klíčové funkce
Grafické posouzení modelu

plotPercentiles() – Srovná empirické a modelové percentily napříč věkem.

plotNormCurves() – To samé pro standardní skóry.

plotRaw() – Porovná pozorované a modelované hrubé skóry.

plotNorm() – Porovná předběžné a modelové normové skóry.

plotDensity() – Zobrazí křivky rozdělení pro zvolené věky.

plot()/plotCnorm() – Další grafy, viz parametry.

Klíčové funkce
Konzistence modelu

checkConsistency() – Kontrola vertikální monotonicity.

plotDerivative() - Graf první derivaci normativního skóru; pomáhá odhalit porušení vertikální monotonicity a problematické oblasti.

- **derivationTable()** – Vrátí hodnoty první derivace při zvoleném věku v tabulce.

rangeCheck() – Upozorní na extrapolaci mimo věkové rozpětí nebo rozsah předběžných normových skórů použitých při odhadu.

getNormScoreSE() – Vyčíslí odchylku modelových od předběžných normových skórů: type = 2 vrací RMSE, type = 1 variantu SE podle dokumentace.

Klíčové funkce
Export, predikce, normativní tabulky

predictNorm() – Převede hrubý skór a věk na normy inverzí Taylorova polynomu.

predictRaw() – Převede standardní skór a věk na odpovídající hrubý skór.

getNormCurve() – Vrátí hruboskórovou křivku napříč věkem při jednom fixním normovém skóru.

normTable() - U Taylorova modelu přiřadí zvolené řadě normových skórů odpovídající hrubé skóry pro jeden nebo více věků.

rawTable() - U Taylorova modelu přiřadí řadě hrubých skórů normové skóry a percentily; při zadání reliability přidá intervaly pravých skórů.

- Tohle si spíše chcete nachystat sami! Pro tyhle účely má normTable() lepší formát.

Klíčové funkce
Další funkce (parametrické modely, GUI)

Parametrické rodiny modelů:

- **cnorm.shash()** – Parametrický model Sinh-Arcsinh pro spojité skóry; s věkem se mohou měnit poloha, měřítko, šikmost a váha konců.
- **cnorm.betabinomial()** – Beta-binomický model počtu správných odpovědí při známém maximálním skóru.
- **cnorm.cmp()** – Conwayův-Maxwellův-Poissonův model pro celočíselné počty, například počet vyřešených úloh v časovém limitu.
- autoselect.shash(), autoselect.betabinomial(), autoselect.cmp() – Výběr stupně věkových polynomů parametrického modelu podle BIC.
- predictMoments() – Vrátí parametry modelů.

cNORM.GUI() – Spustí grafické rozhraní pro klasické normování s Taylorovými polynomy.

cNORM.GUI2() - Spustí grafické rozhraní pro parametrické modelování.

Děkuji za pozornost!

Hynek Cígler

Katedra psychologie
Institut pro psychologický výzkum
Fakulta sociálních studií, Masarykova univerzita

Kontakty:

- E-mail: cigler@fss.muni.cz
- ORCID: http://orcid.org/0000-0001-9959-6227
- GitHub: https://github.com/hynekcigler
- OSF: https://osf.io/t6ufg/
- X: https://x.com/HynekCigler

- **Materiály k tomuto workshopu:** https://github.com/hynekcigler/cnorm_workshop

MUNI FSS Institut pro psychologický výzkum

pdb 2026